

虚拟细胞 × 智能体

VIRTUAL CELLS AS WORLD MODELS FOR DRUG DISCOVERY AGENTS

全文的主张只有一句：领域已经证明的成果集中在“把预测做得更准”，而真正的瓶颈在“用预测决定下一步做什么”。三条彼此独立的负面证据——线性基线未被超越、one-hot 表示不掉点、上下文覆盖而非数据规模决定泛化——共同支持这个判断。因此本报告把智能体设为决策主体，把虚拟细胞设为可替换、可退出的世界模型，并把课题收敛到一处尚未被占据的增量：干预实现的不确定性。

PART 0 - 1

两个主角与技术版图

PART 2 - 3

智能体与决策层形式化

PART 4 - 6

评测、三个方向与候选任务

00 先读这一页

十条判断，以及它们各自的证据强度

核心

标记说明来源：
● **事实** 可被原始论文直接核对 · ● **文献结论** 基于他人消融或独立评测，非本报告主观判断 ·
● **合理推测** 基于前两类的外推 · ● **待验证** 本报告提出、尚未经任何实验检验。

全文唯一的方法学纪律：所有“可以做”的陈述都是待验证设想，所有“已经成立”的陈述都标注原始研究出处，**两类不在同一句中混写。**

50%

397 个抗癌药中与名义靶点建立显著关联的比例^[45]

0

在独立基准上稳定超过简单线性基线的深度扰动模型数量^[15]

5/5

换成零信息 one-hot 表示后性能不降的协同预测模型数^[16]

100×

上下文多样性相对细胞数量的边际价值倍差 (1M/100ctx > 10M/10ctx)^[21]

● **文献结论**

01

两个主角各缺一半

虚拟细胞是有世界模型、无意图的预测器；智能体是有意图、无世界模型的决策器。唯一两边都缺的能力是“知道自己不可信”，这决定了全文的研究议程。

● **合理推测**

02

融合有三个层级，讨论时常被混为一谈

工具级（今天可落地）、闭环级（中期主战场）、范式级（证据薄弱）。领域里可靠的成果几乎全在第一层，却被用来论证第三层的主张。

● **事实**

03

三条独立负面证据指向同一结论

七个深度模型未超过线性基线；one-hot 替换分子表示后协同模型性能不降；上下文覆盖而非细胞数量决定跨背景泛化。方法、团队、数据均不同，结论一致。

● **文献结论**

04

瓶颈在决策层

评价对象不是“系统是否像智能体”，而是三个可测量的量：错误研发行动率、达到同一证据标准的累计成本、前瞻登记的机制预测命中率。

● **事实**

05

“假设—模拟—选实验”已被占据

Model Discovery Agent 已含竞争机制、贝叶斯推断与信息价值；BioDiscoveryAgent、BATCHIE、ScreenShot 已做真实闭环实验选择。三段式流程本身不再是创新点。

● **待验证**

06

唯一尚未被占据的增量：干预实现的不确定性

真实药物证据有三类特有的不对齐：名义剂量 ≠ 功能抑制率、靶点标签 ≠ 完整作用谱、慢性敲除 ≠ 急性蛋白去除。均有硬数据支撑，且可被便宜的桥接实验证伪。

● **文献结论**

07

评测协议必须重写，否则结论不成立

须含 one-hot 基线、leave-drug-out 作为唯一依据、正确暂缓计为成功、成本以孔数与周转时间计、查询数据与最终检验集分离。

● **合理推测**

08

虚拟细胞必须预先写定退出条件

四条：不改善行动排序则移出回路；只提高表达预测则降级为特征提供者；增益来自预训练知识则记为外部信息增益；分布外自信预测错误则收紧适用域。

● **事实**

09

研究议程只保留三个方向

潜空间预测已有 Cell-JEPA 直接先例，集成分歧选择属于既有家族，二者降级为对照。保留：多尺度的干预实现、剂量尺度的交互残差、多模态的能力边界。

● **文献结论**

10

四个任务今天就能启动

证据质量分诊、模式—时间校准基准、先验消融、组合候选分诊——都不依赖湿实验，都能在两到四周内给出明确结论，且都是主线的风险探测器。

全文导航

核心

合订自《虚拟细胞×智能体·研究报告》与《虚拟细胞与智能体·研究判断》两份文件。全文严格区分原始研究结果、分析判断与待验证设想。

PART 0 · 两个主角

01	虚拟细胞：输入输出契约与“不是什么”	4
02	智能体：五个组件、四级自主度与控制回路	5
03	互补结构：世界模型与意图的能力矩阵	6
04	能力分层 L0-L3：拆成可验证的层	7

PART 1 · 虚拟细胞的技术版图

05	AIVC 蓝图、五项优先级与三大推力	8
06	能力阶梯 L1/L2/L3 与因果阶梯	9
07	表示学习路线：Geneformer / scGPT / UCE	10
08	扰动预测路线：GEARS 与 CPA	11
09	异质整合与规模：LPM 与 Tahoe-100M	12
10	上下文学习路线：State / Stack / Cell-JEPA	13
11	多模态（一）：模态版图与信息互补性	14
12	多模态（二）：三种融合范式与失败模式	15
13	多模态（三）：2026 年的多模态模型盘点	16
14	多尺度（一）：四个尺度与跨尺度耦合	17
15	多尺度（二）：时间尺度与剂量尺度	18
16	世界模型化与智能化的七个系统	19
17	评测与竞赛：VCC 2025 → 2026	20
18	三条独立的负面证据	21
19	论文总表与增益归因	22
20	六大瓶颈：从数据到评价	23

PART 2 · 智能体的机制与可靠性

21	形式化 (S,A,π,τ) 与六种推理机制	24
22	工具、记忆与四种多智能体拓扑	25
23	已验证的研究智能体系统	26
24	几何衰减律：可靠性预算约束架构	27
25	MAST 失效分类与架构约束	28
26	智能体评测版图与两处空白	29

PART 3 · 决策层的形式化

27	缺失的决策层：六阶段发现循环	30
28	信念状态、行动空间与信息价值	31
29	世界模型的接口约定与四条退出条件	32
30	四层架构与强制性接口契约	33
31	生物学锚点：干预实现 ≠ 名义干预	34
32	一个案例中的诊断与更新应怎样发生	35
33	需要修正的六项判断	36
34	必须正面对比的最近邻工作	37

全文导航（续）

PART 4 · 证据、评测与落地

35	公开数据能承担什么、不能声称什么	38
36	跨案例决策评测的可执行形式	39
37	指标、基线与收益归因	40
38	验证阶梯与六种典型失效	41
39	AKT、BET 与五个机制控制案例	42
40	首轮八周的交付物与停止标准	43

PART 5 · 三个研究方向

41	从瓶颈到方向：为什么只保留三个	44
42	方向一 · 问题、形式化与多尺度对齐	45
43	方向一 · 模型、训练与可识别性	46
44	方向一 · 实验设计、基线与证伪判据	47
45	方向二 · 交互残差与剂量自治监督	48
46	方向二 · 可识别性、训练与评测	49
47	方向三 · 多模态能力边界图谱	50
48	方向三 · 对抗式证伪协议与交付物	51
49	三个方向的依赖关系与投入顺序	52

PART 6 · 候选任务与分工

50	八个可分别验证的候选任务	53
51	可立即启动的四项：C、D、F、G	54
52	需要条件的四项：A、B、E、H	55
53	三套分工组合与 M1-M4 里程碑	56

结语 · 怎么合起来

54	三个融合层级与它们各自的证据	57
55	四个必要条件与 Q1-Q5 判断	58
56	置信度分层与一页行动清单	59

附录

00	参考文献与核验说明（4 页）	60
----	----------------	----


01 SECTION 01 OF 56

虚拟细胞：一份输入输出契约，不是一个细胞的复制品

核心

虚拟细胞是一个学得的条件分布：给定细胞背景与一次干预，输出该干预下可观测读数的分布。它的全部内容就是这份契约——不是细胞的几何复制，不是一套可解释的生化方程，也不是一个能自己提问的系统。把定义收紧到这一句，是为了让“虚拟细胞有没有用”变成一个可以被实验回答的问题。

图 1.1 · 输入输出契约



它现在确实能做到的 / 做不到的

能做到

- ✓ 把百万级细胞压缩成可迁移的表示，支持细胞类型标注、批次整合、相似性检索
- ✓ 在见过的背景内预测单基因扰动后的转录组整体位移
- ✓ 为检索与假设生成提供先验，作为智能体的一个工具

做不到

- ✗ 在未见背景下稳定地量化扰动特异效应量 [20]
- ✗ 给出可被审计的、区分竞争机制的因果陈述
- ✗ 在分布外条件上主动说“我不知道”——几乎没有模型暴露这个接口

与四个相邻概念的界线

相邻概念	它做的事	与虚拟细胞的关键差别
机制性 ODE / 通路模型	用显式速率方程描述有限分子的动力学	参数有生化含义、可外推但覆盖窄；虚拟细胞参数无含义、覆盖宽但外推无保证
数字孪生	对某一个特定实体持续同化实时数据	虚拟细胞学的是群体条件分布，没有“这一个细胞”的持续状态同化回路
分子模拟 / 结构预测	原子尺度的场力或构象预测	尺度与读数完全不同；二者互补而非替代，虚拟细胞的读数是组学与表型
“更大的生物学 LLM”	在文献与序列上做语言建模	语言模型输出的是叙述，虚拟细胞输出的是可被实验证伪的数值分布

读数模态决定了“预测得准”意味着什么

转录组

信息最丰富、数据最多，但离表型最远。RNA 变化不等于存活变化——第 33 节要修正的判断之一。

形态学

Cell Painting 类通道。便宜、通量高，可与遗传扰动配对，但“形态相似”不能推出“机制相同”。

存活 / 增殖

直接对应研发决策，但维度极低。需按 GR 类指标校正增殖速率与观测时间。

蛋白 / 近端功能

数据最稀缺，却是唯一能测量干预是否真的实现的模态——第 31 节说明它的价值为何被低估。

为什么必须收紧定义：若“虚拟细胞”既指表示学习、又指机制模拟、还指会写报告的智能体，任何一项成果都能被用来支持任何一项主张。后文所有评价——包括第 29 节的四条退出条件——都只针对上面这份契约，契约之外的能力不因共用这个词而自动继承证据。[1][20]

智能体：一个带记忆的控制回路，不是一个更聪明的模型

核心

智能体是一个在环境中反复“感知—推理—行动—观察”并维护内部状态的**控制回路**。判定一个系统是不是智能体，只看一件事：下一步做什么，是它自己根据观察决定的，还是写死在流程里的。这条标准把“更长的提示词”“更多的角色扮演”排除在外，也把本报告的关注点固定在**行动选择**上。

图 2.1 · 最小控制回路



五个必需组件

MODEL 推理内核。负责从观察生成候选行动，不负责决定采纳哪一个。	TOOLS 与环境交互的唯一通道。工具描述必须包含 do_not_use_when，否则模型会在不适用的条件下调用它。	MEMORY 跨步骤的状态。分为工作记忆（本轮上下文）、情节记忆（历史轨迹）与语义记忆（沉淀的结论）。	PLANNER 把目标分解为可执行步骤，并决定何时重规划、何时停止。	CRITIC 对自己的输出做验证与修正。缺少它的系统会把第一个看起来合理的答案当作最终答案。
--	---	---	--	--

四级自主度：把“自主”变成可判定的

等级	定义	后果
A0 · 固定流程	步骤与顺序由人写定，模型只填内容	可复现、可审计，但无法应对未预期的观察
A1 · 条件分支	模型在有限的分支集合中选择	行为空间封闭，失败模式可枚举
A2 · 开放行动	模型自行决定调用哪个工具、调用几次、何时停止	行为空间开放，这里才开始需要可靠性预算（第 24 节）
A3 · 目标自设	系统自己提出要研究什么问题	目前没有任何生物学系统在真实预算下证明过这一层

与两个容易混淆的东西的硬性区分

判别轴	单次模型调用	固定工作流	智能体（A2 及以上）
下一步由谁决定	无下一步	由开发者写死	由系统根据上一步观察决定
失败时的行为	输出错误答案	报错或走到异常分支	可以重试、换工具、或放弃并说明原因
成本可预测性	确定	确定	不确定——这正是必须设预算上限的原因
可审计的对象	输入输出对	流程图	完整轨迹：观察、候选、选择理由与被放弃的选项

本报告建议的落点是 A2，不是 A3。理由是第 24 节的量化约束： $p = 0.95$ 时，要保证整体成功率不低于 80%，可用步数只有 $n \leq \log 0.8 / \log 0.95 \approx 4.3$ 。这不是保守，而是算出来的。^{[38][40][41]}

互补结构：一个有世界模型而无意图，一个有意图而无世界模型

核心

把两者放进同一张能力矩阵，互补关系就不再是修辞。虚拟细胞回答“如果做 a，会看到什么”；智能体回答“为了知道 h，应该做哪个 a”。前者是转移函数 $T(s'|s,a)$ ，后者是策略 $\pi(a|s,goal)$ 。真正值得注意的是矩阵里两边都是空的那一行。

能力矩阵

能力	虚拟细胞	智能体	说明与后果
预测干预结果	✓	✗	智能体只能靠检索到的文献结论近似，无法给出数值分布
表征细胞背景	✓	✗	背景是连续高维对象，语言描述会丢掉决策所需的分辨率
设定目标与终止	✗	✓	模型没有“为什么要预测这个”的概念，也不会主动停止
调用外部证据与工具	✗	✓	虚拟细胞只能看见它被喂进去的那份数据
维护竞争假设	✗	部分	智能体能并列陈述假设，但很少为每个假设登记行动前的判别性预测
按成本排序实验	✗	部分	多数系统把工具调用次数当成本，而非孔数与周转时间
知道自己不可信	✗	✗	两边都缺。这一行决定了第五部分的全部研究议程

合起来之后多出来的能力，以及放大的风险

WORLD MODEL · 虚拟细胞

转移函数

$$T(s' \mid s, a) \approx p(y \mid c, m, d, t)$$

它缺什么：没有 a 的来源，没有目标，没有成本概念，没有“问完就停”的机制。

DECISION MAKER · 智能体

策略

$$\pi(a \mid s, goal) = \operatorname{argmax}_a VOI(a) - \lambda c(a)$$

它缺什么：没有 T 就算不出 VOI。没有世界模型的智能体只能靠检索到的文献结论近似后果。

多出来的能力

唯一真正新增的能力是“在行动之前对后果定价”：智能体可在付出实验成本之前，用世界模型对每个候选行动的结果分布做一次推演，比较信息价值（第 28 节）。若世界模型不改变行动排序，这个能力就没有出现。

放大的风险

世界模型的分布外自信错误，会被智能体的行动选择放大而不是抵消：智能体倾向于选择模型认为信息量大的条件，而模型最容易出错的地方恰恰是它没见过的条件。

一句话的分工：虚拟细胞负责“世界是什么样”，智能体负责“我想知道什么、愿意付多少代价知道”。信念状态只接受真实实验结果的更新；模拟结果只用于规划，不进入证据。这条界线在第 23 节被写成硬性接口约定，是全报告最不可让步的一条。^{[64][65]}

能力分层 L0–L3：把“智能体”拆成可分别验证的层


核心

下表是本报告用于定位工作的分析框架，不是领域既有的共识分类。它的用途只有一个：把“智能体”这个笼统标签拆成可以分别验证的能力层，并指出哪些层已被他人占据、哪些层才是可争取的增量。

能力分层 L0–L3

能力层	智能体实际做的事	已有代表工作	与本课题的关系
L0 · 检索与解释	汇总文献与图谱，生成结构化机制叙述并作计算核验	VCWorld ^[13] 、VCR-Agent ^[27] 、Biomni ^[33]	必须作为基线纳入。文献一致性不是因果验证
L1 · 响应预测	在给定背景与干预下预测读数及其不确定性	CPA ^[7] 、LPM ^[8] 、State ^[10] 、Cell-JEPA ^[9]	作为可替换的世界模型接入，本身不构成课题主张
L2 · 单步实验选择	在候选实验集合中按信息量或收益选出下一个	BioDiscoveryAgent ^[23] 、BATCHIE ^[24] 、ScreenShot ^[25]	强基线。必须在同一预算下被超过，否则无增量
L3 · 诊断、修正与停止	维护竞争机制、选择补证、修正归因，并在证据不足时停止	Model Discovery Agent ^[26] （模型化环境）	本课题落点：真实、异质、不完整药物证据下的 L3

图 4.1 · 占据情况



L0 / L1 的失败

解释流畅但不可证伪；预测精度提升不改变任何实验选择；分布外条件仍给出自信点估计。

L2 的失败

按“最不确定”选点，优先挑到噪声大、异常或无行动价值的条件；把工具调用次数当作实验成本。

L3 的失败

把事后合理解释当成前瞻决策能力；用同一次补测同时充当发现与最终验证；机制空间遗漏时强行归类。

可争取的差异化只剩一处。MDA 的核心已包含竞争机制、贝叶斯推断与信息价值，因此“提出假设→模拟→选高信息实验”不再是充分的算法创新^[26]。真正未被覆盖的是真实药物证据特有的三类不对齐：名义剂量 ≠ 功能抑制率；靶点标签 ≠ 完整作用谱；慢性敲除 ≠ 急性蛋白去除。


● 待验证 第 31、42 节展开。

AIVC 蓝图：两个组件、五项优先级，以及它们今天的完成度

核心

2024 年 Cell 上的 AIVC 纲领把“人工智能虚拟细胞”拆成两个组件：**通用表示（UR）**——把异质测量压进同一个潜空间；**虚拟仪器（VI）**——在该空间中执行“如果做 a 会怎样”的查询^[1]。这份拆分至今仍是领域的组织框架，但两个组件的完成度差距很大：**UR 已有可用产物**，**VI 基本停留在纲领阶段**。

图 5.1 · AIVC 的两个组件



五项优先级与 2026 年 9 月的状态

优先级	纲领要求	当前状态	差距的具体形式
数据规模与多样性	覆盖足够多的细胞类型、扰动与背景	部分达成	总量已达亿级，但上下文覆盖而非细胞数量才是瓶颈 ^[21]
通用表示	跨模态、跨物种的统一潜空间	部分达成	单模态表示成熟；真正的跨模态配对数据仍极少（第 11 节）
干预预测	预测未见扰动、未见背景下的响应	未达成	未见背景下未稳定超过线性基线 ^{[15][20]}
可解释与机制对齐	预测能追溯到可检验的机制陈述	未达成	多数解释是事后叙述，缺少干预一致性检验 ^[72]
开放基准与社区	统一、防作弊、可复现的评测	进行中	VCC 已建立（第 17 节），但划分设计仍是主要争议点

推动这一波的三股力量，以及各自的边界

数据侧

单细胞测序成本下降 + 组合索引，使 Perturb-seq 类实验从千级扩到百万级；Tahoe-100M 把化学扰动做到亿级细胞^[12]。边界：扩的是同一批细胞系的更多药物，不是更多背景。

架构侧

Transformer 让基因—基因、细胞—细胞长程依赖可学；自监督预训练把无标签数据变成可用信号。边界：重构目标把 90% 以上的 dropout 当成信号来学^[9]。

算力与工程侧

与 LLM 共享的训练栈几乎零成本迁移到单细胞领域。边界：算力解决的是拟合，不解决因果传输^[21]。

一个容易被忽略的结构事实：三股力量全都作用在 UR 上，没有一股直接作用在 VI 上。表示学习能从无标签数据中获益，而干预预测只能从带干预标签的数据中获益——后者的增长速度受湿实验通量限制，与算力无关。这解释了为什么“再等两年模型就够好了”是一个没有机制支撑的期待。

能力阶梯：表示、预测、干预设计，以及它们与因果阶梯的对应

核心

上一节的 L0–L3 分的是智能体的能力；这一节分的是**虚拟细胞的能力**。两者正交，不要混用。虚拟细胞的三级阶梯与 Pearl 的因果阶梯几乎逐级对应——这个对应不是类比，而是可推导的结论：**每上一级所需的数据类型都严格强于下一级**，因此不能靠在低一级上做得更好来跨级。

能力阶梯与因果阶梯的对应

阶梯	回答的问题	因果阶梯对应	所需数据	当前证据强度
L1 · 表示	这个细胞是什么？与那个细胞像不像？	第一级 · 关联 $P(y)$	大量无扰动观测数据即可	强 · 跨数据集标注与整合已可用
L2 · 预测	做了干预 a 之后会变成什么样？	第二级 · 干预 $P(y \text{do}(a))$	必须有配对的干预—响应数据	中 · 见过的背景内可用；未见背景下不稳定 ^[20]
L3 · 干预设计	要达到目标状态，应该做哪个干预？	第三级 · 反事实 $P(ya a',y')$	需可靠的机制约束或大量反事实证据	弱 · 尚无在真实预算下的前瞻验证

为什么不能靠 L1 做得更好来到达 L2

L1 的训练信号来自“同一分布内的相似性”，L2 的训练信号来自“干预前后的差异”——数学上不是同一个目标。检验方法：把模型在 L1 指标上的排名与 L2 指标上的排名列在一起，若两列不相关，“表示更好所以预测更好”就不成立^{[9][15]}。

L2 到 L3 之间还隔着一个可执行性缺口

即便 L2 完美，L3 仍不自动成立：模型可以算出“把基因 X 表达降到 30% 就能达到目标状态”，但现实中没有一个试剂恰好实现 30%。这个缺口是第 31 节的主题。

一个可直接执行的判别实验：取任一 L2 模型，输入“名义剂量 d”与输入“实测功能残余 r”两种条件，比较预测误差。若后者显著更低，说明名义剂量确实是有损的代理变量——这为第五部分方向一提供第一块证据，且不需要任何新的湿实验。

论文自我定位与证据实际支持的层级之间的落差

工作类别	自我定位	证据支持	落差的来源
单细胞基础模型（Geneformer / scGPT / UCE）	L1 → L2	L1	扰动任务用的是微调后的下游头，而非预训练目标本身带来的能力
扰动预测模型（GEARS / CPA / State）	L2 → L3	L2（见过的背景内）	“可用于设计干预”是推论，未经前瞻实验检验
世界模型类（VCWorld / GenBio）	L2 → L3	L1 + 检索	机制叙述由知识检索产生，与预测模块的因果贡献未被分离
智能体类（CellForge / Biomni）	L3	工程自动化	自动化的是建模流程，不是生物学发现

本报告的立场：目前有实证支撑的主张只到 L2，且限于见过的背景。L3 是值得投入的目标，但任何 L3 主张都必须附带前瞻登记的判别性预测与冻结后的独立检验（第 36 节），否则它与“事后找到一个说得通的解释”无法区分。^[69]

表示学习路线：把一个细胞变成一个可比较的向量

核心

这条路线要解决的问题是：单细胞表达矩阵既高维又极稀疏，且批次效应常常大于生物学信号。三个代表工作给出三种不同的应对方式，差别集中在“**如何把表达量编码成 token**”这一步——这一步的选择决定了模型对技术噪声的敏感度。

图 7.1 · Geneformer 秩值编码



关键点：只保留相对顺序而丢弃绝对数值，天然抵抗测序深度与批次差异——代价是丢失了效应量信息

四个代表工作

工作	要解决的问题	关键创新	代价与已知局限
Geneformer	批次效应淹没生物学信号；绝对表达量不可跨实验比较	秩值编码：把细胞表示为基因按相对表达排序的序列	抗批次，但效应量信息被丢掉——而这恰恰是扰动任务需要的量
scGPT	缺少可同时服务多种下游任务的统一骨架	分箱表达 + 生成式预训练，统一四类任务	独立评测中，在多项任务上未稳定超过 PCA 等简单基线 ^[17]
UCE	不同物种、不同基因面板之间无法共享模型	用蛋白质序列嵌入表示基因，零样本跨物种嵌入	零样本迁移强，但同样不提供干预语义；序列相似不等于功能相似
scFoundation	参数与数据规模是否能带来质变	1 亿参数、5000 万细胞，读深感知的非对称编解码器	提供了“规模不足以解决问题”这一结论的直接证据点

三种 token 化方式的直接后果

编码方式	抗批次	保留效应量	支持未见基因	对扰动任务的净影响
秩值编码 (Geneformer)	强	否	否	适合表型分类，不适合需要量化差异的扰动任务
分箱表达 (scGPT)	中	部分	否	分箱边界即信息损失上限；细微剂量差异被压平
蛋白序列嵌入 (UCE)	强	否	是	唯一能处理跨物种与新基因；扰动语义仍需另行提供

应当给这条路线的信用

它确实解决了一个真问题：跨数据集的细胞类型标注、批次整合与相似性检索现在有了可直接调用的通用组件。这是工具级融合能够立刻落地的技术基础，也是本报告唯一给出“证据强”评级的层级。

这条路线的共同盲区

四个模型的自监督目标都是重构表达，其中没有任何一项与“干预”有关——它学的是细胞长什么样，不是动它一下会怎样。把这些表示直接接到扰动任务上，本质是期待一个从未被训练过的能力自动涌现^[9]。第 18 节给出三条实证证据说明它没有涌现。

扰动预测路线：GEARS 的外推假设与 CPA 的可加分解

核心

这条路线直面 L2：给定一个从未测过的扰动，预测它的转录组后果。两个代表工作代表两种互补的假设——GEARS 假设“相似的基因有相似的扰动效应”，CPA 假设“多个扰动的效应在潜空间中可加”。两个假设各自成立于一部分条件，而它们各自失效的方式，恰好定义了第五部分方向二的问题。

GEARS · 图上邻居聚合

A、B、C 已测；X 未测 → X 的效应由图上邻居聚合而来
基因共表达图 + GO 本体图 → GNN 聚合 → 可预测双基因组合

图 8.1 GEARS 把未见扰动问题转成图上邻居聚合问题

CPA · 潜空间可加组合

组合响应
 $z + e_A + e_B \rightarrow \text{解码器} \rightarrow \text{组合响应}$

图 8.2 CPA 的可加潜空间分解，及其自报的“主导效应”退化：组合数据不足时，模型退化为只预测较强的单药

工作	问题与创新	已验证的能力	失效边界
GEARS	未见扰动没有可学的表示。用共表达图与 GO 本体给扰动一个由邻居决定的嵌入	单/双基因扰动的转录组后果预测；能给出非加性的定性提示	依赖“图上相近→效应相近”这一强假设；图本身来自已有知识，对真正新颖的基因帮助有限
CPA	剂量、时间、细胞系与药物身份纠缠在一起。用对抗训练把它们解耦成可加的潜向量	剂量外推、未见药物组合的转录组预测；在真实组合数据上验证	原文即报告：组合数据不足时退化为“主导效应”，这正是方向二要处理的对象

在讨论“协同”之前必须先固定零模型

BLISS 独立性 · 概率独立假设

$$E_{\text{Bliss}} = E_A + E_B - E_A \cdot E_B, S = E_{AB} - E_{\text{Bliss}}$$

LOEWE 相加性 · 等效剂量假设

$$d_A/D_A(E) + d_B/D_B(E) = 1$$

两个必须记住的后果：其一，模拟出来的表达向量不提供上式中的任何一个 E——它们是转录组，不是归一化表型抑制率，必须用真实表型训练该映射并传播误差。其二，Bliss 不满足同药自组合检验：把一个药物与它自己组合，Loewe 按构造给出无协同，而 Bliss 一般会给出虚假协同——这个差别在第 45 节会变成一个免费监督信号的入口。^[59]

异质整合与规模：LPM 的三维解耦与 Tahoe-100M 的一亿细胞

核心

前两条路线各自处理一类数据。真实世界的问题是：成百上千个实验用不同的扰动、不同的读数、不同的背景做出来，彼此不可直接比较。LPM 给出了一个结构化的解法，Tahoe-100M 给出了一个规模化的解法——把两者放在一起看，能清楚地读出“规模到底买到了什么”。

图 9.1 · LPM 的三维解耦



张量补全式建模：任一维度上的空格都可被其余二维推断——这让“哪一维缺数据”成为可诊断的问题

LPM [8]

问题：公开扰动数据分散在成百上千个实验里，直接合并会把批次当成生物学。创新：把“扰动/读数/背景”表示为三个正交维度，跨实验整合变成张量补全，机制配对由此成为可计算的查询。对本课题的意义：它是目前最接近“可替换世界模型”接口要求的公开模型。

Tahoe-100M [12]

问题：化学扰动的单细胞数据量级远小于遗传扰动。做法：约 1 亿个单细胞、覆盖数十种癌细胞系与上千种小分子，构成迄今最大的化学扰动图谱。边界：它扩的是同一组细胞系上的更多药物，对“未见背景”帮助有限。

规模到底买到了什么：一个可以直接对照的表

维度	规模化能改善	规模化不能改善
同背景内的新药物	能 · 更多化合物覆盖⇒更密的局部支撑	—
未见细胞背景	—	不能 · 需要的是上下文数量，不是每个上下文里的细胞数 [21]
干预实现的不确定性	—	不能 · 数据里根本没有“实际抑制了多少”这一列（第 31 节）
校准与拒绝外推	—	不能 · 这是目标函数问题，不是数据量问题

读表的方式：右列的三行是本报告全部研究议程的来源。它们的共同特征是——再多同类数据也不会让它们自己消失，必须靠改变测量内容、改变目标函数或改变评测设计来解决。

上下文学习路线：State、Stack 与 Cell-JEPA 的三种“不再微调”

核心

2025–2026 年最明显的范式变化是：不再为每个新背景微调模型，而是把该背景的少量样本直接塞进上下文。三个工作从三个角度实现了这一点——State 换掉预测对象，Stack 换掉输入单元，Cell-JEPA 换掉训练目标。它们共享一个动机：逐细胞重构表达是一个错误的学习信号。

State^[10] · 换预测对象

问题：逐个细胞预测扰动后表达，信噪比极低。创新：预测细胞群体分布的位移而非单个细胞的表达。意义：与决策需求一致——研究者关心的是这群细胞整体会怎样。

Stack^[11] · 换输入单元

问题：迁移到新细胞系通常须微调，新系数数据往往只有几百个细胞。创新：把整块细胞×基因矩阵作为输入单元，表格式注意力双向建模。意义：推理时无需梯度更新即可少样本适配。

Cell-JEPA^[9] · 换训练目标

问题：dropout 率超过 90% 时，重构目标在训练模型编码测量伪影。创新：学生编码器从掩码输入预测教师对完整输入的潜表示。零样本聚类 AvgBIO 0.72 对 scGPT 0.53。

三种目标函数在学什么

目标函数	做法	含义
重构目标（scGPT / Geneformer）	掩码基因 → 预测其表达值	噪声也必须被预测对
潜空间预测（Cell-JEPA）	掩码输入 → 预测教师的潜表示	噪声在潜空间中被自然滤掉
分布位移（State）	一组细胞 + 干预 → 群体分布	直接对齐决策所需的量

“上下文”在三个模型中指的不是同一件事

工作	上下文的内容	对智能体接口的含义
State	一组该背景下的未扰动细胞	智能体只需提供“这批细胞长什么样”，无需标注
Stack	一整块细胞×基因矩阵（可含已知扰动示例）	智能体可把已有实验结果直接作为示例塞入，实现无梯度更新的在线适配
Cell-JEPA	同一细胞的未被掩码部分	上下文是自监督内部机制，不构成对外接口

一个必须记录的查新结论：“把 JEPA 式潜空间预测引入细胞建模”已有直接先例——Cell-JEPA 于 2026 年 2 月公开^[9]。因此任何以“细胞版 JEPA”为名的方案都不能承担原创主张，只能作为模型对照。该论文自身也指出：绝对表达状态的改善未充分转化为扰动效应量的改善，这与独立线性基线评测^[15]互为印证，共同构成第 18 节的核心证据。

11

SECTION 11 OF 56

多模态（一）：每种模态回答的是不同的问题，不是同一个问题的不同视角

核心

多模态在这个领域常被当作“加通道提性能”的工程手段。本报告采取一个更窄也更可操作的定义：不同模态在因果链上处于不同位置，因此它们能回答的问题不同。转录组告诉你细胞“状态变了”，蛋白读数告诉你“干预是否真的发生”，存活读数告诉你“这件事是否值得继续做”。

模态在因果链上的位置

模态	在因果链上的位置	能独立支撑的结论	不能支撑的结论	数据可得性
化学结构 / 遗传试剂	干预的名义定义	化合物相似性、系列归属	实际作用谱——名义靶点只覆盖一部分作用 [45]	充足
靶点占有 / 蛋白丰度	干预的实现	药物确实结合/降解了目标蛋白	结合占有率不等于功能已被抑制	极稀缺
近端功能读数	干预的功能后果	该酶活性下降了 x%——方向一的核心变量	下游通路的整体重排	极稀缺
转录组	细胞状态重排	状态位移的方向与幅度、通路富集	存活协同——RNA 变化不是药效真值（第 33 节）	充足
形态学（Cell Painting）	细胞状态的正交投影	与转录组独立的表型指纹；便宜、高通量 [57]	“形态相似⇒机制相同”	充足
空间转录组 / 组织学	细胞在组织中的位置	微环境依赖的响应异质性	单细胞层面的干预因果	增长中
存活 / 增殖	研发决策终点	该条件下是否值得推进	为什么有效或无效	充足（需 GR 校正 {cite(22)}）

读这张表的关键：数据最充足的三个模态（结构、转录组、存活）恰好跳过了中间两层。公开数据能大量告诉你给了什么药、细胞后来怎么样了，却几乎从不告诉你这个药在这个细胞里到底把目标功能压下去了多少——这个空缺不是偶然，它是第 31 节生物学锚点与第 42 节方向一的全部动机。

“配对”这个词被用得太空

真正配对的资源：两个

CPJUMP1^[57]：303 个化合物、160 个基因，在 A549 与 U2OS 两个细胞系上做匹配的化学与遗传扰动形态学读数。Haghighi 等^[58]：跨 28,000 个遗传与化学扰动的表达与形态联合谱。

常被误当作配对的：三种

① CPJUMP1 的配对发生在形态学模态内部，不是跨 RNA 与形态。
② JUMP 与 Tahoe 的细胞系、时间点与处理流程都不同。③ 不同实验中的同名化合物：盐形式、批次、实际浓度、供应商都可能不同。

一个必须保留而非消除的混杂：CPJUMP1 中化合物处理为 24/48 小时，CRISPR 为 96/144 小时，ORF 为 48/96 小时。这不是数据缺陷，而是干预模式与时间窗的真实耦合——正确做法是把模式与时间同时作为条件变量显式入模（第 15、29 节），并在评测中分层报告。

多模态（二）：三种融合范式，以及它们各自会怎样失败

核心

融合发生在三个可能的位置：特征层（早期）、表示层（中期）、决策层（后期）。位置越早，要求的配对越严格、可获得的数据越少；位置越晚，越容易实施、但能建模的跨模态关系越弱。本课题的取舍是“后期为主、中期为辅、不做早期”。

早期融合 · 特征拼接

RNA + 形态 → 单模型。需严格同一样本配对，数据量最小。

中期融合 · 表示对齐

RNA、形态各自编码器 → 共享潜空间。对比学习、部分配对即可，但强模态易支配弱模态。

后期融合 · 决策层聚合

RNA、形态、存活各自独立证据 → 信念更新与一致性检验。不需要样本级配对，模态间的不一致本身成为信息。

本课题的取舍：后期融合为主——决策层需要的恰恰是“不同证据是否相互矛盾”，这个信号在共享潜空间中会被抹平。中期融合仅用于已有大量部分配对的模态对（形态↔表达）；早期融合的配对要求在本领域无法满足。

四种必须预先防范的失败模式

模态支配

训练时某一模态信号强、噪声小，模型学会只用它。对照：逐模态消融必须是标准动作。

伪配对

用化合物名或基因名做连接键。对照：以实验元数据而非名称建立连接，无法确认的配对标为缺失。

对齐即因果

两个模态的表示能对齐，被读作反映同一机制。对照：对齐只说明存在共享方差；因果需要干预一致性检验^[72]。

缺失模态的静默填补

用模型补出未测模态再当证据。对照：缺失必须是一个状态；补出的值不得进入信念更新。

按模态对逐一给出建议

模态对	现有配对数据	建议融合位置	理由与前置条件
形态 ↔ 转录组	Haghighi 等，2.8 万扰动 ^[58]	中期	唯一有足够配对量的模态对；须逐条件核对匹配，不能按化合物名连接
化学扰动 ↔ 遗传扰动（形态）	CPJUMP1，303 化合物 / 160 基因 ^[57]	中期	模式一时间混杂必须作为条件变量保留，不得对齐掉
转录组 ↔ 存活	大量，但跨实验而非同孔	后期	缺环在此：映射必须用真实表型训练并传播误差（第 33 节）
蛋白 / 近端功能 ↔ 任意	几乎没有	后期（先补数据）	这是方向一要主动生产的数据，不是可以从公开资源拼出来的

与“可信虚拟细胞”路线图一致的一条建议：不要强行把所有模态压进统一潜空间，而应按部分配对处理，并系统性地把转录组与正交表型配对，防止“模型只复现了训练模态”这一自我确证失效^[72]。模态间的不一致不是需要被消除的噪声，而是需要被建模的信号——它正是第 47 节能力边界图谱的原始材料。

多模态（三）：2026 年的多模态基础模型，以及它们各自证明了什么

核心

2026 年上半年出现了一批把影像、空间与蛋白模态接入单细胞建模的基础模型。总体判断先给出：这一批工作显著推进了 L1（表示），但没有一个提供 L2 意义上的跨背景干预预测证据——它们扩展的是表示的覆盖面，不是干预语义。

工作	模态与规模	建立了什么	没有建立什么
PAST ^[73]	组织病理影像 + 单细胞转录组，2000 万对，泛癌种	细胞级的跨模态统一表示	未给出干预后响应预测；配对来自同一切片的空间共定位
scpFormer ^[74]	单细胞蛋白组，3.9 亿细胞 / 530+ 蛋白	异质蛋白平台的统一表示——稀缺模态首次有基础模型	覆盖表面标志与信号蛋白面板，不是靶点占有或酶活
SpatialFusion ^[75]	空间转录组 + H&E 组织学，通路先验引导	细胞邻域的联合嵌入	微环境作为条件变量进入干预预测的路径尚未打通
显微影像 MAE ^[77]	大规模显微影像自监督	影像模态的可扩展预训练	与分子模态的对齐仍需外部配对数据

这批工作对本课题的真实价值

scpFormer 改变了方向一的可行性判断：现在有了跨平台的蛋白表示骨架，小规模桥接实验的数据能被有效利用。PAST 与 SpatialFusion 把“上下文”从细胞系标签扩展为连续变量。

必须同时记住的三条限制

① 所有配对都是观测性共现，不是干预下的配对。② 规模数字衡量训练量，不是上下文覆盖。③ 都没有报告校准或拒绝外推，按接口约定只能作为特征提供者。

读一篇多模态工作时应当先问的四个问题

① 配对是怎么来的

同一细胞？同一孔？同一样本的不同切片？还是只是同一化合物名？前三者强度依次递减。

② 去掉一个模态会怎样

是否报告了逐模态消融？若没有，无法排除模型只用最强的模态。

③ 增益体现在哪一层

表示质量提高，还是干预预测提高？前者是 L1，后者才是 L2。

④ 缺失模态怎么处理

是标为缺失，还是被模型补齐？若补齐，补出的值是否被排除在评测之外？

给团队的一条具体建议：不要用“我们做多模态”作为课题的新颖性来源——这条赛道在 2026 年已经相当拥挤。值得做的是把多模态用于判断模型何时不可信，而不是用于把预测做得更准。第 47 节把这一想法展开为方向三。

多尺度（一）：四个生物学尺度、三处耦合，与一条被跳过的链路

核心

2026 年 Briefings in Bioinformatics 的多尺度 AIVC 综述把虚拟细胞的建模对象分成四个功能层级：基因→蛋白→通路→细胞，并指出三处相邻尺度耦合与三类核心困难^[71]。本报告采用这个框架，但要补上一条它没有强调、而对药物发现至关重要的链路。

图 14.1 · 四个尺度与被跳过的中间三格



虚拟细胞实际建模的范围通常被整体跳过：直接从“给了什么药”映射到“细胞状态”——跨尺度困难：非线性跃迁、模态语义失配、维度爆炸

每个尺度的数据基础极不平衡

尺度	代表资源	量级
基因	ClinVar / HGMD	> 600 万 / $\approx$ 30 万
蛋白	PDB / UniProt	> 20 万结构 / > 50 万条目
通路	STRING / BioGRID	275 亿 / $\approx$ 290 万相互作用
细胞	HCA / Tabula Sapiens	6000 万+ / 500 万+ 细胞

注意这张表的陷阱：数量最大的是通路尺度的相互作用条目，但其中绝大多数是预测或文本挖掘得到的关联，置信度差异极大。把它们不加区分地当作先验注入模型，正是第 51 节任务 F 要用打乱边对照去检验的事情。

药物发现真正需要的那条链路



端到端模型用一个函数近似了这条链。当链条中每一环都被某个未观测变量调制时，这个近似在换背景时必然失效——而它失效的具体方式，恰好就是第 31 节要区分的三类竞争解释。^{[47][48]}

多尺度（二）：被普遍折叠掉的两个维度——时间与剂量

核心

空间层级之外还有两个尺度维度，它们在多数建模工作中被当作超参数而非建模对象：**时间与剂量**。二者的共同点是：它们都不是单调的标签，而是连续的、且与干预模式强耦合的变量。

图 15.1 · 时间尺度与干预模式的耦合

时间窗	代表现象	干预模式典型窗口
分钟-小时	近端信号传导，最接近“干预是否实现”	小分子可测
24-48 小时	转录组重排，已混入反馈但未被代偿完全掩盖	小分子标准窗口（CPJUMP1 24/48h）
48-96 小时	ORF / 降解表型	ORF 48/96h
96-144 小时	CRISPR 存活表型，细胞已有充分时间启动代偿	CRISPR 96/144h

干预模式与时间窗天然绑定：比较“小分子 24h”与“KO 144h”时，模式差异与时间差异无法分离。这正是慢性敲除 ≠ 急性蛋白去除的机制来源，也是降解剂与 CRISPR 敲除在同一靶点上给出不同结论的常见原因之一^{[49][50]}。

剂量尺度：名义浓度并不是干预强度

把相对残余功能记为 $r \in [0,1]$ ，背景 c 下的存活响应记为 $V_c(r)$ 。若两个背景的耐受阈值不同，中间剂量区间会产生选择性。部分抑制与完全缺失产生不同选择性已有直接研究^{[47][48]}——“部分抑制存在阈值”不能写成新发现。

真正值得检验的

一类可测的功能状态与背景条件，能否预测未见靶点或化合物系列何时可以迁移，并据此指导更便宜的验证。这是第 42 节方向一的问题陈述。

四类干预模式在两个尺度上的特征

干预模式	功能去除的时间常数	强度是否可调	典型混淆
小分子抑制	分钟级、可逆	连续可调	名义浓度 ≠ 胞内暴露 ≠ 占有率
降解剂 / PROTAC	小时级、持续	部分可调	降解更强不自动证明非催化功能——需先匹配近端功能轨迹 ^[49]
CRISPR 敲除	天级、不可逆	全或无	泛致死时掩盖选择性；拷贝数伪影
CRISPRi / RNAi 敲低 ^[48]	天级、部分	连续可调	脱靶；表达量下降 ≠ 酶活下降同等幅度

这张表解释了为什么“遗传依赖与药理表型不一致”是常态而非例外^[46]：四种模式在时间常数、可调性、去除对象三维上都不同。两个尺度必须一起处理： r 不是标量而是轨迹 $r(t)$ ——现有数据几乎总是只在一个时间点测一次表型、从不测 r ，这正是第 44 节最小桥接实验的由来。

世界模型化与智能体化：七个系统，以及它们各自自动化了什么

核心

2025–2026 年出现的这批系统都把虚拟细胞从模型推向系统。阅读它们时最有一个区分是：被自动化的是建模流程，还是生物学发现？前者是扎实的工程贡献，后者是需要前瞻实验才能支持的科学主张。

系统	关键设计	自动化的对象	已建立 / 未建立
VCWorld ^[13]	知识图谱检索 + 机制推理 + 表达变化预测串联	建模流程	建立：知识可结构化注入预测。未建立：需同骨架消融才能归因
GenBio ^[14]	多尺度虚拟细胞世界模型的整体架构蓝图	概念框架	建立：一份可讨论的提案。未建立：尚无对应公开定量评测
VCR-Agent ^[27]	机制作用图（20 个生物学原语）+ 验证器过滤	解释的结构化	建立：解释可系统核验、可证伪——L0 层最扎实的一步。未建立：核验的是文献一致性，不是因果
CellForge ^[30]	多智能体自动完成分析、方法设计、代码实现	建模流程	建立：端到端建模可自动化。未建立：未带来新的生物学结论
AblateCell ^[31]	先复现、再消融的智能体，系统性拆解组件贡献	证据核验	建立：自动化消融可行——第 37 节模块互换正是这一思路。未建立：不产生新方法
Virtual Biotech ^[32]	靶点发现到候选评估全链路的多智能体编排	流程编排	未建立：验证以回顾性相关为主，不能支撑“可替代研发流程”
Biomni ^[33]	统一工具环境，覆盖数百个工具与数据库	工具环境	建立：可复用基础设施，本课题可直接借鉴。未建立：不证明专项机制诊断能力

这批工作真正的共同贡献

证明了科研流程的自动化可行：复现、消融、代码生成、工具编排、解释结构化，且质量可审计。对人力有限的小组，这是可以立刻借用的杠杆（第 51 节）。

这批工作共同缺的一件事

没有一个系统报告了冻结之后的前瞻实验检验。评价方式几乎都是回放、比对已发表结论、或 LLM 评审打分——都无法排除“事后合理化”。

关于 VCWorld 归因的一处必要更正：更换 LLM 骨架造成更大的性能变化，不能证明知识图谱没有贡献——两个因素的效应量不可直接比较，除非在同一骨架下做匹配消融。正确的结论是：当前证据不足以把增益归因给知识图谱。这一区分是第 37 节收益归因方法的直接来源。

评测与竞赛：从 VCC 2025 到 VCC 2026，标准提高了一整个量级

核心

评测设计是这个领域过去一年进步最快的部分，也是最值得本课题借鉴的部分。Virtual Cell Challenge 两届之间的变化，几乎就是一份关于“什么样的划分才算数”的公开教材。

VCC 2025^[18] · 首届

任务：在单一细胞类型内泛化到未见扰动。数据：提供训练集。指标：扰动判别、差异表达、平均绝对误差。定位：把“虚拟细胞图灵测试”变成可提交、可排名的任务。

VCC 2026^[19] · 第二届

任务：零样本跨背景——六个从未见过扰动的细胞系。数据：不发放训练集；三系验证榜，三系隐藏终测。指标：六项指标聚合排名，抑制单指标刷分。

三处值得本课题直接抄的设计

隐藏测试集与验证榜分离

三个细胞系用于公开榜单调参，三个完全隐藏用于最终排名——对应第 36 节“查询结果与最终检验必须分离”。

多指标聚合而非单指标

直接回应“不同指标给出不同排名”这一已被独立基准证实的现象^[20]。

零训练集

彻底消除“在与测试集同分布的数据上微调”这条捷径。

但仍有一处不适用于本课题：竞赛评的是预测，本课题评的是决策。即便某个模型在 VCC 上夺冠，也不能推出它能改善实验选择——这两件事之间的联系，正是第 37 节模块互换要测量的对象。

独立基准给出的量化结论

- ✓ 常规设置下模型表现被系统性高估；严格条件下性能显著下降^[20]
- ✓ 性能高度依赖任务设计与评价标准，不同指标产生实质不同的排名
- ✓ 模型对跨细胞背景的分布迁移鲁棒性有限
- ✓ 即使简单线性模型也能抓住整体趋势，但在未见扰动上都无法还原扰动特异的细粒度效应

第四条尤其关键

它说明当前模型的“预测能力”主要来自捕捉所有扰动共有的全局位移，而决策需要的恰恰是区分不同扰动的那部分信号。第 18 节的三条证据从三个方向说明了同一件事。

其余三项应当纳入视野的工作	检验的对象	对本课题的用法
one PCA still rules them all ^[17]	转录组基础模型在扰动分析任务上是否优于 PCA	表示层的平凡基线：任何“我们的表示更好”的论证必须先过这一关
线性基线基准 ^[15]	七个深度模型 vs 刻意简单的线性基线	预测层的平凡基线，直接提供第 51 节任务 D 的对照
OPAL ^[29]	决策时刻的信息是否足以授权自适应实验	决策层唯一的近邻：预测价值高不足以更改实验计划

18 SECTION 18 OF 56

三条彼此独立的负面证据，指向同一个结论

核心

如果只有一项研究说“深度模型没有优势”，那可以归因于实现细节或数据选择。本节列出的三项工作方法不同、团队不同、数据不同、任务不同，却都指向同一个结论：当前瓶颈不在模型容量，也不在分子表示的精细程度。这是本报告全部议程的实证基础。

证据一 · 线性基线未被超越^[15]

做法：五个基础模型 + 两个深度模型，与刻意简化的线性基线对比单/双扰动预测；修订中补入 Geneformer、scBERT、UCE。结果：没有一个超过线性基线。边界：结论限于其测试的模型、数据与协议。

证据二 · 分子信息可被整体替换^[16]

做法：五个已发表协同预测模型，把药物与细胞系表示全部换成 one-hot。结果：性能持平甚至更好；leave-drug-out 下还不如训练集平均值。含义：模型学到的主要是实体身份与数据集偏置。

证据三 · 覆盖面而非数据量^[21]

做法：2200 万细胞 T 细胞数据集上比较细胞数量与上下文多样性的贡献。结果：驱动跨背景泛化的是上下文多样性；100 万/100 背景优于 1000 万/10 背景。含义：这是因果传输问题。

图 18.1 · One-hot 替换实验的定性结果

原始分子表示
基准性能



全部换成 one-hot
持平或更高



leave-drug-out 下
低于“取平均值”这一平凡基线

示意图，用于表达三种设置之间的定性关系，非原文数值的精确复制。第三格是最关键的一格：换一个切分方式，模型就输给了平均值

对三条证据的四种常见反驳，以及它们各自成不成立

反驳	是否成立	理由
这些评测用的模型不是最新的	部分成立	确实存在时滞，但三项工作覆盖的架构代际不同，2026 年独立基准 ^[20] 在更新模型上得到同方向结论
线性基线在某些指标上占优，换指标就不成立了	不成立	这恰恰是证据的一部分：不同指标给出实质不同的排名 ^[20]
one-hot 结论只适用于药物协同任务	部分成立	原文确实限于协同预测，但它与线性基线基准在完全不同任务上得到同方向结论，交叉印证反而更强
规模化还没到拐点，再等等	不成立	证据三直接检验了规模假设：增加同背景细胞数的边际收益远低于增加背景数，这是对“再等等”的直接反例

三条证据合起来说明的事：把资源继续投向更大的模型、更精细的分子表示、同分布的更多数据，边际收益很低。没有说明的事：虚拟细胞方向本身有问题——三条证据针对的都是评测协议与数据结构，这正是为什么本报告的三个方向全部指向“知道预测对不对”，而不是“把预测做得更准”。

论文总表：每项工作的增益是否可归因

核心

最后一列是本表的重点。“增益可归因”指论文提供了足以把性能提升归到其所主张机制上的对照（消融、同骨架替换、打乱对照、独立评测确认）；“存疑”不表示结论错误，只表示现有证据不足以排除其他解释。

工作	层	核心主张	归因	存疑之处 / 支撑对照
Geneformer ^[2]	L1	秩值编码 + 预训练带来可迁移的网络生物学能力	清楚	少样本微调有对照；扰动任务表现由独立基准另行界定
scGPT ^[3]	L1	统一骨架服务四类下游任务	存疑	独立评测中未稳定超过 PCA ^[17]
UCE ^[4]	L1	蛋白序列嵌入实现零样本跨物种	清楚	跨物种零样本设置本身即是对照
GEARS ^[6]	L2	知识图谱使未见扰动可预测	清楚	有去先验对照；但“图上相近→效应相近”对新颖基因是强假设
CPA ^[7]	L2	解耦的可加潜空间支持剂量与组合外推	清楚	原文自报主导效应失效边界——罕见的诚实披露
LPM ^[8]	L2	三维解耦实现跨异质实验整合	清楚	结构设计与任务对应明确
Cell-JEPA ^[9]	L1	潜空间预测优于重构目标	清楚	自报：表达状态改善未充分转化为扰动效应量改善
State / Stack ^{[10][11]}	L2	预测分布位移 / 上下文学习实现免微调迁移	存疑	与线性基线的对比需按第 36 节的划分重做
Tahoe-100M ^[12]	数据	亿级化学扰动图谱	清楚	数据集贡献明确；但扩的是药物数而非背景数
VCWorld ^[13]	L0+L2	知识图谱提升预测与机制解释	存疑	换 LLM 骨架效应更大；需同骨架匹配消融
VCR-Agent ^[27]	L0	机制作用图使解释可核验	清楚	形式化与验证器可检查；核验对象是文献一致性
BioDiscoveryAgent ^[23]	L2	LLM 先验驱动的迭代扰动选择	清楚	有随机与主动学习基线对照
BATCHIE ^[24]	L2	贝叶斯主动设计的真实组合筛选	清楚	探索 4% 实验空间后前瞻验证成功——含真实实验闭环
MDA ^[26]	L3	LLM 提机制 + SMC/SBI + VOI 的模型发现	清楚	在物理、化学与神经电生理三域验证；但均为模型化环境
CellForge / AblateCell ^{[30][31]}	工程	自动建模 / 自动消融	清楚	自动化对象是流程，不是发现
Virtual Biotech ^[32]	L0	多智能体覆盖治疗发现全链路	不足	回顾性相关不是因果验证

读表的一条建议：“存疑”集中出现在两类工作上——声称统一多任务能力的大骨架，以及把多个组件串起来后整体评测的系统。二者的共同点是：增益的可能来源太多，而对照的数量不够多。第 37 节给出的模块互换与打乱对照，正是把这一列从“存疑”变成“清楚”的标准操作。

六大瓶颈：它们各自能被什么解决、不能被什么解决

核心

把前十五节的观察归纳为六个瓶颈。最重要的一列是“不能被什么解决”——它决定了哪些问题会随着算力与数据自然消失，哪些不会。本报告的三个方向全部取自“不会自然消失”的那一类。

瓶颈	具体表现	能被什么解决	不能被什么解决
① 上下文覆盖	换一个细胞背景，模型性能显著下降 ^[20]	增加背景数量；把背景表示为连续变量	不能 · 在已有背景上增加细胞数 ^[21]
② 干预实现未被观测	数据里没有“实际抑制了多少”这一列	小规模桥接实验：近端功能 + 匹配时间窗表型	不能 · 任何规模的转录组数据——这一变量不在其中
③ 无校准、不会拒答	分布外条件仍给出自信点估计	改目标函数（区间覆盖、Brier）；保形预测	不能 · 更多数据或更大模型——这是目标函数问题
④ 评测协议不匹配	随机切分下的高分，在 leave-drug-out 下低于取平均 ^[16]	支撑感知的划分、多指标聚合、one-hot 基线	不能 · 换模型——问题在协议不在模型
⑤ 增益不可归因	系统整体更好，但说不清是模型、检索、还是策略带来的	模块互换、打乱对照、同骨架匹配消融	不能 · 增加论文中的对比方法数量
⑥ 缺少决策层	预测精度提升不改变任何实验选择	把预测接进信息价值计算；用错误行动率评价	不能 · 继续优化预测指标

会自然消失的

暂时没有。六个瓶颈中没有一个仅靠算力增长或同分布数据积累就能解决——这本身是本报告最重要的结构性结论。

靠协议与方法学解决的

③④⑤。它们不需要新数据、不需要湿实验，可以立刻开始，且失败判据清晰。对应第 51 节的四个可立即启动任务。

需要新测量的

①②。前者需要更多背景，后者需要功能强度读数。二者都是数据生产问题，也都是方向一的前置条件。

图 20.1 · 瓶颈的依赖顺序



从瓶颈到议程的映射，在第 41 节完整给出。预先说明结论：方向一对应瓶颈②与①，方向二对应瓶颈⑤在组合场景下的特例，方向三对应瓶颈③。瓶颈④与⑥不单独立为研究方向，而是作为贯穿三个方向的评测纪律写进第四部分。

21 SECTION 21 OF 56

形式化与六种推理机制：哪些改变了行动选择，哪些只改变了文字

核心

一个智能体可以写成四元组 (S, A, π, τ) ：状态、行动、策略、转移。它与强化学习的差别不在形式，而在**策略的来源**——RL 的 π 由大量试错习得，LLM 智能体的 π 由预训练先验加上下文即时构造。这带来一个关键后果：它不需要在该任务上训练，但也没有任何收敛保证。

图 21.1 · 三种推理结构

AGENT (S, A, π, τ)

S 已获证据、当前信念、历史轨迹 **A** 检索、计算、调用模型、发起实验、停止 **π** 由预训练先验+上下文构造，无收敛保证 **τ** 真实世界的响应，部分可观测、有噪声、有成本

与 RL 的关键差别：RL 中 τ 可被模拟器无限采样；这里 τ 的每一次采样都是一次真实实验，代价以孔数与周转周计——长程探索型算法在本领域不可直接移植（第 33 节）。

六种机制：作用对象与是否改变行动

机制	作用对象	改变行动？	在本课题中的用法与代价
CoT ^[36]	把隐式推理展开为显式中间步骤	否	提高可审计性，但不改变选择；单路径的错误会一直传下去
自治投票 ^[37]	采样多条路径后取多数	间接	抑制随机性错误；不能抑制系统性偏差——多个相似模型一致不是可靠性证明
ToT ^[39]	显式维护搜索树并回溯	是	适合行动空间小而结构清晰的问题；成本随分支数指数增长，需预算上限
ReAct ^[38]	推理与工具调用交替	是	本课题的基本循环形式：每一步的观察都来自真实数据而非模型自述
Reflexion ^[40]	失败后生成语言化反馈并重试	是	需要可靠的失败信号；若失败判据本身由模型给出，会退化为自我确证
RAG	用检索到的外部文本约束生成	否	必须固定检索语料并隔离可泄漏结论的正文与补充材料（第 36 节）

选择机制的唯一标准：它是否改变行动。表中三个标为“是”的机制值得投入工程成本，标为“否”的两个只改善叙述质量——它们有价值，但不应被计入方法创新。一个系统加了 CoT 之后“解释更清楚了”，却没有任何一次实验选择因此改变，这个区分在评审中经常被模糊。

工具、记忆与拓扑：三个容易被低估的工程决定

核心

这三项通常被当作实现细节，但它们决定了系统的失败模式。三条具体建议：**工具描述必须包含否定条件、记忆必须分层且可追溯、拓扑应选星形而非全连接**——最后一条有第 24、25 节的量化依据。

工具 schema：一个被普遍省略的字段

```
PREDICT_RESPONSE

inputs:{c,mode,dose,time} → outputs:
{mean,interval,in_distribution}
do_not_use_when: [背景不在训练覆盖内, 剂量超出训练区间两倍, 干预模式与训练时不同]
```

为什么必需：模型不会自发推断工具的适用边界，只说它能做什么，就会在任何看似相关的情形下调用它。这个字段把第 29 节的“拒绝外推”变成调用方可见的硬约束。

记忆的三层，以及可信度处理

层	内容	可信度处理
工作记忆	本轮上下文	易被长上下文稀释 ^[43] ，需主动摘要
情节记忆	历次行动、观察与结果	只记录，不解释；解释存在语义层
语义记忆	沉淀下来的结论	必须标注来源与证据强度，模拟结果不得写入

一条容易造成后验虚假自信的细节：多篇文献若源自同一次实验（原始论文、综述、数据库条目），只能计作一个来源簇。把它们当作独立证据反复相乘，会让信念状态迅速收敛到错误的结论上。

四种多智能体拓扑与它们的失效方式

流水线

固定顺序传递。失效：上游错误无法被下游发现，误差单向累积。

星形 / 编排者

中心节点分派并汇总。失效：中心成为瓶颈，但错误可在汇总处被拦截——本课题推荐。

全连接辩论

角色互相质询。失效：通信量随角色数平方增长，且相关模型倾向于收敛到同一个错误。

分层

多级编排。失效：层数增加使可靠性按第 24 节的规律衰减，责任归属难以审计。

本课题原型所需的工具清单，及其计费方式

工具	作用	计入计算成本	计入实验预算
evidence_query	按靶点/化合物/背景检索已揭示的真实证据与元数据	是	否
predict_response	调用可替换的世界模型，返回分布与适用域标记	是	否——模拟不消耗实验预算
list_available_actions	返回当前案例实际可揭示的实验菜单与各自成本	是	否
reveal_result	支付成本，揭示一项真实实验结果	—	是——按孔数与周转时间计
register_prediction	登记行动前的判别性预测（不可事后修改）	—	—

已验证的研究智能体：谁真正做了闭环实验，做到了哪一步

核心

“闭环”这个词被用得很宽。本节只收录确实产生过真实实验结果或在真实数据上做过序贯决策回放的系统，并逐一标注它们闭到了哪一环。这七个系统共同构成本课题必须正面对比的基线集合（第 34 节）。

系统	做了什么	闭环程度	对本课题的意义
BioDiscoveryAgent ^[23]	用 LLM 先验与反馈，迭代选择下一批要敲除的基因	数据回放闭环	证明 LLM 先验可以替代专门训练的获取函数。强基线——必须在同预算下被超过
BATCHIE ^[24]	贝叶斯主动学习分批设计组合筛选；仅探索 4% 可能实验即可准确预测新组合	真实前瞻实验	本领域最强的序贯筛选基线。其尤因肿瘤组合经后续实验确认
ScreenShot ^[25]	40 个筛选数据集预训练，用少量功能测量做上下文学习预测组合响应	数据回放闭环	直接竞争工作。功能测量本身就是最有效的上下文——与方向一前提一致
Model Discovery Agent ^[26]	LLM 提机制结构，SMC 做后验，SBI 处理似然，VOI 设计实验	模型化环境	方法学上最接近本课题，使“假设—模拟—选实验”不再构成创新点
DeMeo 等 ^[28]	转录组辅助的主动表型筛选，用真实实验反馈迭代改进	真实前瞻实验	“模型接实验形成闭环”已有先例，不能单独作为首创主张
OPAL ^[29]	问“该不该允许自适应”：预先承诺的契约、受控目标风险、扣除成本后的正执行价值	冻结后独立评价	11,265 化合物分区上，六种方法中唯一兼顾非零激活与风险控制
Coscientist / ChemCrow ^[35]	LLM 驱动的化学实验规划与执行	真实前瞻实验	跨领域证明自主实验可行；但化学反应验证远比细胞表型归因直接

这七个系统合起来已经覆盖的

LLM 先验驱动的实验选择；贝叶斯主动设计的前瞻成功；少量功能测量的免微调迁移；竞争机制+贝叶斯更新+信息价值的完整方法学；风险受控的自适应授权判断。

它们合起来仍未覆盖的

干预非等价性（都把“做实验 a”当作确定实现了 a）；证据不可比；机制空间不完备；可辩护的暂缓——没有系统把“证据不足”作为被奖励的终局。

OPAL 值得单独强调：它提出的问题是本报告第三部分同构——预测价值高，不足以更改实验计划。它先建立不可能性边界，再导出目标校准的可恢复条件，说明本课题的问题空间已有人用严格方式处理，必须正面对比。^[29]

几何衰减律：为什么“再加一个智能体”通常让系统更差

核心

如果一条任务链有 n 个必须全部正确的串行步骤，每步独立成功率为 p ，则整体成功率约为 p^n 。这个粗略模型把“系统应该多复杂”从审美问题变成算术问题——在高可靠性区间，缩短链条比提升单步质量更划算。

几何衰减律

$$P \approx p^n, n \leq \log P^* / \log p$$

单步 p	$n=5$	$n=10$	$n=20$
0.90	59%	35%	12%
0.95	77%	60%	36%
0.99	95%	90%	82%

把目标定为 $P^*=80\%$ ： $p=0.90$ 只允许 2 步， $p=0.95$ 允许 4 步， $p=0.99$ 允许 22 步。当前 LLM 在需要精确检索与数值推理的生物学子任务上，单步可靠性通常落在 0.90–0.95 区间。

更乐观的一面：边际收益并非递减

$n^*=\log P^*/\log p$ 对 p 高度敏感，单步准确率的微小提升带来可完成任务长度的指数级增长：从 0.95 提到 0.99，允许步数由 4 跳到 22^[42]。

更悲观的一面： p 不是常数

自条件化效应：模型看到自己先前的错误留在上下文里时，后续出错概率上升——真实衰减快于 p^n ，长上下文的信息稀释^[43]会放大它。

把预算算在一个具体流程上

步	动作	估计单步 p	为什么是这个量级 / 如何提高
1	提取实验条件并判定可比性	0.90–0.95	结构化抽取；元数据规则兜底可提到 0.98+
2	生成有限的竞争机制假设	0.90	受机制空间完备性限制；固定模板+兜底类可提高
3	为每个候选行动登记判别性预测	0.95	格式化任务，可由 schema 强制校验
4	按 $VOI-\lambda c$ 排序并选择（或暂缓）	0.99	交由统计程序，不由 LLM 直接输出后验
合计	四步串行	$\approx 0.77\text{--}0.81$	恰好落在 80% 目标线上——这不是巧合，而是先定预算再定架构的结果

对本课题架构的三条直接约束：① 串行深度上限四步——第 30 节因此设计为四层而非自主循环。② 每一步都必须有可独立校验的中间产物。③ 增加角色数量不是能力增强，而是可靠性削减——除非新增角色并联用于交叉校验而非串联于主链。

MAST 失效分类：多数失败不是推理不行，而是规范与协作出了问题

核心

MAST^[41] 系统性分析了多智能体 LLM 系统的失败轨迹，把失败归为三大类。这项工作的价值在于：它表明大部分失败可以靠架构约束消除，而不需要更强的模型。本节把每一类失败翻译成本课题的一条具体设计规定。

- 一 · 规范与任务定义失效

系统提示与任务目标不一致；角色越权；步骤重复；缺少终止条件。
- 二 · 智能体间对齐失效

上下文在传递中丢失或被截断；术语理解不一致；推理链断裂；无效的澄清请求。
- 三 · 任务验证与终止失效

过早终止；验证缺失；验证不完整（只检查格式）；错误被接受为最终结果。

翻译成本课题的架构规定

失效模式	在本课题中的具体形态	对应的架构规定
缺少终止条件	智能体不断补测，或过早宣布机制已确定	把停止与暂缓写入行动空间 A，正确暂缓计为成功（第 37 节）
术语不一致	“药物无效”同时指多种不同状态	在 schema 层面把三者分成互斥状态值，禁止用同一标签（第 35 节）
验证不完整	检查预测格式合法，未检查是否在适用域内	接口契约中 in_distribution 与 abstain_reason 设为必填（第 30 节）
角色越权	LLM 直接给出定量后验，而非交由统计程序拟合	硬性分工：LLM 提取/生成/解释；统计程序拟合/校准/选择（第 28 节）
上下文丢失	多轮之后，早期的证据质量标记被丢弃	情节记忆只追加不覆写；每轮快照含完整字段
错误被接受	模型生成的解释流畅，评审据此通过	失败判据必须由数据而非模型给出（第 21 节）

轨迹日志的最小字段集：round_id、evidence_snapshot、hypotheses[]、candidate_actions[]、**rejected_actions[]**（最常被省略也最关键）、chosen_action、observed_result、belief_update_delta、stop_decision。没有 rejected_actions 的记录，就无法判断改善来自新信息、响应模型，还是选择策略。

与第 24 节合起来的统一设计原则：可靠性不是靠让每个智能体更聪明获得的，而是靠让系统结构更少依赖每个智能体都正确获得的——缩短串行链、把状态外置为可审计的数据结构、把“不知道”变成合法且被奖励的输出。第 30 节将三者合并为一个四层架构。^[44]

智能体评测版图：已有的覆盖面，与两处结构性空白

核心

智能体评测在通用领域已相当成熟^[44]，但把这套方法搬到科学发现场景时会暴露两处结构性空白。这两处空白不是“还没人做”，而是**现有范式无法表达**——它们正是本课题评测设计（第四部分）必须自己解决的部分。

评测维度	通用领域的做法	科学发现场景的差距
任务完成率	pass@k、pass^k（k 次全对）	需重定义“完成”：给出正确结论 vs 给出正确的下一步
工具使用正确性	调用序列与参数的匹配度	需补上“不该调用时是否没调用”
成本效率	token 数、调用次数、时延	不可移植：实验成本以孔数、试剂与周转周计，与 token 无关
鲁棒性	对抗提示、噪声输入	需补上“反证响应”：新证据反对初始解释时能否改变判断
决策价值	空白	空白一 ：没有基准衡量系统是否让研究者做出更好的下一步决定
恰当弃权	空白	空白二 ：几乎所有基准都惩罚“不回答”，系统被训练成永不弃权

空白一：决策价值没有基准

现有基准问“答案对不对”，科学发现场景真正要问的是：在这个证据状态下，推荐的下一个实验是不是最值得做的那个？这正是第 36 节要构建的东西，也是本课题最有可能产生独立学术价值的交付物。

空白二：弃权被系统性惩罚

在几乎所有基准中，“我不知道”与“答错了”得分相同——这对科学发现是方向性错误。本报告的处理方式：对证据不足的案例，正确暂缓计为成功行为（第 37 节），同时设反向对照防止系统学会“永远怀疑”。

因此本课题必须自建的四项评测组件

组件	内容	没有它的后果
带成本的行动菜单	每个案例列出实际可揭示的实验及其孔数、试剂负担与周转时间	无法比较“达到同一证据标准的累计成本”
分级揭示接口	按预算逐步揭示真实结果；不存在的实验标为不可用	策略可以把所有标签逐步揭示完，把记忆当成泛化
始终隐藏的检验集	一组永不供策略读取的结果，用于检验跨干预预测与停止决定	发现与验证共用同一批数据，结论不成立
弃权合法的评分函数	正确暂缓计为成功；同时含可迁移案例作为反向对照	系统被优化成永不弃权，或反过来永远弃权

四项的总工作量并不大，且全部不依赖湿实验——这是第 51 节把评测基础设施列为第一优先级的原因。一个可直接借用的通用指标：pass^k（k 次独立运行全部成功）。本课题的所有主指标都应报告全部运行的分布，把方差作为结果的一部分，而不只报告最佳运行。

缺失的决策层：六个阶段里，现有工作只覆盖了两个

核心

把一次药物发现迭代拆成六个阶段，就能看清前两部分的所有工作落在哪里。虚拟细胞覆盖“预测”，智能体覆盖“检索与解释”，两端之间的**选择、执行、更新**三个阶段几乎无人覆盖——不是因为它们不重要，而是因为它们无法用现有的预测指标评价。

图 27.1 · 六阶段发现循环



工具级融合只接通①②；闭环级融合要求接通③④⑤⑥——现有工作密集覆盖①②，③④⑤⑥几乎无人覆盖

为什么被跳过：没有数据结构

公开数据只有“实验做了、结果如此”，没有当时有哪些候选、为什么选它、成本多少。缺了这些，③无法被评价。

为什么被跳过：没有损失函数

预测有明确的误差定义，而“选错实验”的代价取决于研发情境，必须由人事先约定（第 28 节的 $L(d,h)$ ）。

为什么被跳过：没有真值

一个案例往往没有唯一正确的实验序列，评测须从“对比标准答案”改为“对比可接受行动集合”（第 37 节）。

跳过它们的代价有一个具体数字：OPAL 在未见 11,265 化合物分区上，把“是否授权自适应”作为需要被冻结规则判定的问题，选出 595 个化合物、捕获 384 个正机会，误激活上界 $5.18\% < 7.5\%$ ——六种方法中只有它同时做到非零激活与风险受控。另外五种方法要么从不激活，要么激活但风险失控。^[29]

逐阶段对照：谁覆盖了、用什么评价、缺什么

阶段	代表工作	现行评价方式	缺口
① 提出假设	VCR-Agent、VCWorld、Biomni	与文献一致性、专家/LLM 评分	假设是否互斥且可判别未被要求
② 预测后果	GEARS、CPA、LPM、State	相关系数、MAE、差异表达重合	无校准、无适用域、无拒答
③ 选择实验	BioDiscoveryAgent、BATCHIE、ScreenShot	命中率、达到覆盖所需实验数	目标是找到命中而非区分机制；成本常以调用次数计
④ 执行实验	DeMeo 等、Coscientist	是否产出真实结果	结果与行动前登记的预测未被对照
⑤ 更新信念	MDA（模型化环境）	后验收敛速度	真实证据的不可比性未被建模
⑥ 决定去留	OPAL（授权判定）	误激活率、执行价值	仅覆盖“是否自适应”，未覆盖推进/修正/停止三分

一个常被援引、但必须修正的类比：把虚拟细胞类比为强化学习的世界模型（Ha & Schmidhuber 的 V/M/C，或 DreamerV3），在结构上恰当，但在数据上不成立——独立的扰动快照不是离线强化学习轨迹（第 33 节第五项）。第三部分的任务就是把③④⑤⑥补上：信念状态与价值函数（第 28 节）、接口约定（第 29 节）、四层架构（第 30 节）、生物学锚点（第 31 节）。^{[64][65]}

决策层的形式化：信念状态、行动空间与信息价值

核心

一个案例定义为“靶点或靶点集合、细胞背景、源干预、目标干预、时间、终点及已有证据”的组合。研究对象是这条具体的迁移命题，不是给某个基因永久贴上“可药/不可药”的标签。

信念状态

$$b_D(h, \theta) = p(h, \theta \mid D)$$
$$p(y \mid a, D) = \sum_h \int p(y \mid a, h, \theta) p(h, \theta \mid D) d\theta$$

风险与信息价值

$$R(D) = \min_d E_h[D[L(d, h)]]$$
$$VOI(a) = R(D) - E_{y \mid a, D}[R(D \cup \{(a, y)\})] - \lambda c(a)$$

D · 已获得的真实证据

模拟结果永不进入D。

h · 可并存的机制因素

非互斥标签，必须含一个“未覆盖机制”兜底类。

θ · 干预强度、动力学与测量模型参数

三者的不确定性分开记录。

行动空间：五类，最后一类最容易被漏掉

- ✓ 读取尚未揭示的正交证据（另一平台、另一读数）
- ✓ 补测靶点作用或蛋白丰度——方向一的核心行动
- ✓ 改变时间窗或干预模式（抑制 ↔ 降解 ↔ 敲除）
- ✓ 验证背景因素（基因型、代谢状态等）
- ✓ 停止或暂缓——必须是合法行动，且在评测中被奖励

两条硬性禁令：缺少结果的历史实验不能由代理模型生成“真值”；没有可靠结果预测的实验不应被赋予伪精确的 VOI。

分工：LLM 与统计程序的边界

LLM 负责	统计程序负责
从异质记录中提取与核验实验条件	拟合 $p(h, \theta \mid D)$
生成有限的候选假设	校准与区间估计
提出可执行的行动菜单	计算 VOI 并排序选择
解释结果、撰写可审计记录	判定停止阈值

为什么用一步 VOI，而不是长程 RL

三条理由

- ① 没有轨迹数据：扰动快照是独立快照，不含动作序列与状态转移。
- ② 采样代价不可忽略：每次采样都是真实实验。
- ③ 马尔可夫性不成立：证据单调增长且永不遗忘，更接近信息状态。

这条边界有第 24 节的量化依据：把排序与选择交给确定性程序，可把该步单步可靠性从约 0.90 提到 0.99，在四步链条上相当于整体成功率提高约十个百分点——比更换更强的 LLM 效果更大，成本却低得多。算法主张不能只是重新使用 VOI：待验证的增量在于计算价值时显式考虑证据不可比、干预实现不确定、机制可并存、机制空间未覆盖、实验不可执行五项。

虚拟细胞作为世界模型：接口约定，与四条预先写定的退出条件

核心

在本课题中，虚拟细胞不是研究对象，而是回路中的可替换组件。它只在规划阶段被调用，预测“执行行动 a 会看到什么”，为价值排序提供分布；信念状态只接受真实结果的更新。

图 29.1 · 世界模型在回路中的位置



接口项	约定	为什么这样定
输入	细胞背景、干预模式、名义剂量与实测强度、作用时间、终点、批次与质量标记	模式与时间是已知混杂，必须显式入模 ^[57]
输出	读数的预测分布（含区间），附适用域标记与外推拒绝位；不接受纯点估计	决策需要的是不确定性的形状；点估计无法进入 VOI 计算
可替换体	线性基线 → 层级剂量响应模型 → CPA / LPM / State → 潜空间模型 ^{[7][8][9]} [10]	同一接口下互换，才能把收益归因到模型而非流程
可见数据与计费	候选模型共享同一可见证据与实验菜单；模拟调用计入计算成本，不计入实验预算	避免泄漏标签制造虚假优势

三条硬性要求

一 · 校准优先于精度：先看区间覆盖率与 Brier/log score，再看均方误差。二 · 拒绝外推：严重分布外条件必须输出“不可预测”。三 · 贡献可归因：模块互换，并设“去掉模型”与“打乱模型预测”两个对照。

- 四条退出条件 · 预先写定，不事后调整
- ✗

若模型不改善行动排序 → 从回路中移除
- ✗

若提高表达预测却不改变实验选择 → 降级为特征提供者
- ✗

若改善只来自预训练知识 → 记为外部信息增益
- ✗

若模型在分布外条件上自信地预测错误 → 收紧适用域并单列该类失败

已知边界必须写进方法部分，而不是留到讨论里：深度学习的扰动效应预测尚未稳定超过简单线性基线^[15]；潜空间中表达状态的改善未充分转化为扰动效应量的改善^[9]。预先写明这两条，等于承认“世界模型可能被证明是多余的”是一个允许发生的结果——这把本课题与“先假定模型有用、再找证据支持”的工作区分开来。

四层架构与强制性接口契约

核心

架构只有四层，因为第 24 节的可靠性预算只允许四步串行。每层之间的接口是结构化数据而非自然语言——这是把 MAST 的“上下文丢失”与“术语不一致”从根上消除的手段。加粗字段是必填但当前几乎所有系统都没有的。

层	职责	输出（必填字段加粗）
L1 · 证据层	把异质记录归一为带条件与质量标记的证据表；判定真冲突/条件不可比/证据不足	records[], conflicts[], comparability_status , missing_reason
L2 · 世界模型层	对每个候选行动给出结果分布；可替换、可移除、可打乱	mean, interval, in_distribution , abstain_reason , model_id
L3 · 决策层	计算 VOI-λc 并排序；输出选择、被放弃的候选与理由；可输出暂缓	chosen, rejected[] , rationale, registered_predictions[] , defer_flag
L4 · 执行与更新层	揭示真实结果，更新信念；唯一允许写入 D 的层	observed, belief_delta, contradiction_flag , stop_decision

必填字段一 · in_distribution

模型必须自报本次预测是否落在训练覆盖范围内。没有它，决策层无法区分“模型说会有强响应”与“模型在猜”。

必填字段二 · rejected[]

被放弃的候选行动及其理由。没有它，无法判断改善来自新信息、模型，还是选择策略（第 25、37 节）。

必填字段三 · contradiction_flag

新结果是否与先前的解释矛盾。若整个评测中该标志从未置位，说明系统从不改变判断——这本身就是一个失败结论。

一轮完整往返的样例（简化，但字段齐全）

L1 → L2 → L3 → L4

L1{conflicts:[{target:TGT-1,genetic:K0降低存活,pharma:抑制剂10μM无表型}], comparability_status:条件不可比}

L2{action:测近端功能, mean:0.62, interval:[0.31,0.88], in_distribution:false, abstain_reason:该背景不在训练覆盖内}

L3{chosen:测近端功能@48h, rejected:[{a:全转录组@144h,why:成本8倍判别力更低}], defer_flag:false}

L4{observed:残余功能71%, belief_delta:{H1:+0.34,H2:-0.22}, contradiction_flag:false, stop_decision:继续}

这一轮真正起作用的是哪一项？不是预测数值，而是 L2 自报的 in_distribution:false——它使 L3 下调了该预测的权重，转而选择判别力更高、成本更低的行动。若删掉必填字段：去掉 in_distribution，L3 会把不可信的预测当作可信；去掉 rejected，无法证明比较过其他选项；去掉 registered_predictions，任何解释都能说成早就预料到了。

一条实现建议：四层之间用文件而非函数调用连接。换来三样：任一层可被单独替换以做消融、每次运行天然留下完整轨迹、中间结果可被人直接审阅。

生物学锚点：干预实现 ≠ 名义干预

核心

本报告建议把“相同的功能改变是否产生相同的表型”作为核心生物学问题。在限定的靶点与背景内，考察迁移失败究竟来自**功能改变没有实现**，还是来自**不同模式改变了不同的功能**。这个问题可以用少量桥接测量证伪。

50%

397 个抗癌药中能的名义靶点建立机制关联的比例；19.9 万条药敏测量 × 484 细胞系^[45]

3

真实药物证据特有的不对齐类型，见下表

≈ 0

公开扰动数据中带有“实测功能残余”这一列的比例

100年+

同药自组合的经典判据（Loewe）已有近百年历史，本报告只是把它用作免费监督信号

三类不对齐，以及各自最有判别力的比较

竞争解释	最有判别力的比较	结果的含义
不同背景的实际抑制率不同	按实测功能残余量比较响应，而非只按名义剂量	对齐后差异消失 ⇒ 支持“干预实现差异”
背景具有不同的功能耐受阈值	在相近残余功能与相同时间窗下比较表型	差异仍在 ⇒ 支持“背景调节”；仍需因果操作确证
催化功能与其他蛋白功能不同	急性蛋白去除与催化抑制配对，加入合适的救援	单一残余酶活无法解释 ⇒ 需做功能分解
药物另有主导作用对象	正交化合物、功能保留的耐药等位基因及作用谱	名义靶点相关性不足以支持药效归因

这一判断建立在既有原始研究之上

部分抑制与完全缺失产生不同选择性已有直接研究^[47]；表达滴定与基因特异阈值也有先例^[48]。降解的实际选择性可不同于配体结合选择性^[50]；AKT 降解剂 INY-03-041 降解三个亚型并产生更持久的下游抑制^[49]。

测量技术已经存在

药理效应不能简单等同于蛋白缺失：PARP 抑制剂需要蛋白存在并形成有毒复合物^[51]，这是“KO 不复现不等于脱靶”的经典反例。CETSA 可在完整细胞中直接测量靶点结合^[55]，缺的不是方法，是把它纳入建模数据的习惯。

值得检验的是什么：不是“阈值存在”，而是一类可测的功能状态与背景条件，能否预测未见靶点或化合物系列何时可以迁移。这句话里每个部分都可被证伪：“可测”要求给出具体读数；“预测”要求前瞻登记；“未见”要求 leave-target-out 划分；“更便宜”要求成本核算。PRMT5/MTAP 应作为已知条件控制，而不是被重新包装成发现^{[53][54]}。


最便宜的先导实验应当很小：只覆盖几个靶点与背景，测量实际蛋白/近端功能及匹配时间窗的表型。若这些桥接变量不能改善跨模式预测，正确反应是先修改机制假设，而不是扩大到全转录组——这条纪律同时是第 40 节停止标准的一部分：小实验给出否定结果时，扩大规模是最常见也最昂贵的错误反应。

一个案例中，诊断与更新应当怎样发生

核心

以下是 workflows 示意，不是本次得到的实验结果。输入为：某基因 KO 降低存活，而名义抑制剂在受测条件下无效。系统必须先核对细胞、终点、作用时间、遗传试剂特异性与药物有效浓度范围，而不是立即解释成非催化功能。

图 32.1 · 案例流程



分叉点在“条件是否可比”，而不是在“哪个机制更合理”——若不可比，记录条件缺口并标为伪冲突，从实验清单中剔除

阶段	系统必须产生的可检验内容
初始假设	H1: 实际功能抑制不足; H2: 去除蛋白改变了抑制剂未影响的功能; H3: 遗传表型或名义靶点归因不可靠。允许并存，保留“未覆盖机制”兜底类
行动前预测	为每个可执行实验列出各假设下的预期结果与不确定性。例如：实测近端功能几乎不变→更支持 H1；但结合占有率不能证明功能已被抑制
选择补证	已有证据若缺点作用测量，优先评估该测量的价值；排序依赖成本与当前证据，而非假设的先验合理性
结果与修正	若改善暴露后实现功能抑制并产生表型→更新为条件性迁移；若充分抑制仍无效→降低 H1，保留模式差异与归因问题
独立检验	在未用于更新的另一化合物或背景上，事先预测再实际检验。不能用同一次补测同时充当发现与最终验证
停止与交付	输出当前支持的解释、排除到何种程度、建议改变什么、仍缺何种证据；证据无法区分时明确暂缓

“最少实验”必须相对于明确的行动门槛

如果两个解释导向同一下一步行动，可以暂不区分；如果它们导向相反的研发决策，就必须优先补证。这条规则把“机制好奇心”与“决策必要性”分开。

基准记录必须包括未被采用的候选行动

保留每轮的证据快照、假设、各行动的预测、选择原因、真实结果、更新与停止依据——没有这些，很容易把事后合理解释误当成前瞻决策能力（第 4 节 L3 失败模式第一条）。

这个案例同时演示了架构为什么必须是四层：“核对条件是否可比”是 L1 的职责，如果与“提出机制假设”混在同一步，系统会在条件不可比时直接跳到机制解释——这是真实评审中最常见的错误，也是第 51 节任务 C（证据质量分诊）被列为主线前置模块的原因。

调研中需要修正的六项判断

核心

以下六项来自对原始文献的复核，每一项都改变了本报告的写法，但没有一项否定课题本身。在正式成文前修正，比在评审意见里被指出要便宜得多。

项	修正前的表述（不成立）	修正后的表述（可成立）
一	组合扰动与闭环决策目前基本空白	组合与闭环均有强基线；增量须体现为同一预算下的决策收益
二	用模型预测组合转录组，进而给出协同分数	用真实表型训练转录组→协同的映射，并报告传播后的不确定性
三	提出细胞版 JEPa 作为原创方向	将 Cell-JEPa 作为模型对照纳入可替换体清单
四	用集成分歧作为实验选择的创新目标	以 query-by-committee 为基线，比较决策风险下降而非不确定性大小
五	把扰动数据当作离线 RL 轨迹训练世界模型	采用一步 VOI；状态定义为已有证据及其不确定性
六	已有配对的多模态数据可直接使用	仅两个资源真正配对；VCWorld 归因待同骨架消融后再下结论

一 · 组合扰动与决策层不能再按“基本空白”定位

CPA 原文已用组合数据验证未见组合响应^[7]；BioDiscoveryAgent 已迭代选择基因扰动^[23]；BATCHIE 已有真实序贯组合筛选^[24]。它们足以否定“加上组合或闭环就是新方向”。

二 · 从转录组到协同分数存在缺失环节

Bliss/Loewe 都要求真实表型响应（第 8 节）。模拟出的表达向量不提供其中任何一个 E，必须用真实表型训练并验证该映射，且把误差传播进去。

三 · Cellular JEPa 已有直接先例

2026 年 2 月的 Cell-JEPa 已做潜空间预测^[9]。该方向可作模型对照，不能以名称或架构类比承担原创主张。

四 · 集成分歧选择属于既有主动学习家族

以集成方差为目标的选择接近 query-by-committee，可能优先选到噪声大、无行动价值的条件^[24]^[26]。应比较决策风险的下降，而非假设“最不确定”就最值得做。

五 · 独立扰动快照不是离线强化学习轨迹

缺少同一系统的动作序列、状态转移与奖励。实验决策可以是序贯的，但其状态首先是已有证据及不确定性。

六 · 多模态数据与模型归因都需重新核对

CPJUMP1 的配对不等于 JUMP、Tahoe 在相同条件下配对测了 RNA^[57]。VCWorld 归因需同骨架下的匹配消融^[13]。

六项共同决定了主张的写法：本课题不能以“首次把组合/闭环/世界模型引入药物发现”立论，只能以“在指定的真实决策任务上，相对已有强基线降低错误行动与成本”立论。这个句式看起来保守，实际上更难被推翻——一个可以被精确反驳的主张，比一个无法被反驳的宏大主张更有学术价值。

必须正面对比的最近邻工作，以及各自还须证明什么

核心

下表中“已提供的能力”依据原始论文与官方记录；ScreenShot 与 MDA 的结果仍属预印本报告，不预设其优势在本任务上可复现。右栏是本课题若要成立，必须在同一预算与同一证据菜单下证明的内容。

工作	已提供的能力	本课题还须证明什么
CPA / LPM ^{[7][8]}	组合或异质干预响应建模；LPM 联合扰动、读数与背景三维度	功能差异表示确实改变补证决策，而不只是多加一个输入字段
BioDiscoveryAgent ^[23]	基于先验知识与反馈，迭代选择基因及基因组合	从寻找命中扩展到区分机制与停止，且收益独立成立
BATCHIE ^[24]	贝叶斯主动设计的真实组合筛选，含前瞻实验确认	同预算下超越固定数学选择器，或解决其未评估的诊断目标
ScreenShot ^[25]	少量功能测量驱动的组合响应预测与主动选择，免微调	组学/机制证据提供可归因的增量，而不仅是提高系统复杂度
VCWorld / VCR-Agent ^{[13][27]}	知识支持的预测、机制解释与结构化计算核验	新实验能排除竞争机制；文献一致性不是因果验证
Model Discovery Agent ^[26]	LLM 提机制、贝叶斯更新、信息价值选实验	异质且不完整的真实药物证据、干预非等价性及真实成本下的收益
DeMeo 等 ^[28]	组学辅助的主动表型筛选，及实验反馈改进	不可用“模型接实验形成闭环”单独主张首创
OPAL ^[29]	冻结契约下判定是否授权自适应，风险受控	从二元授权扩展到推进/修正/停止的三分决策

MDA 尤其改变了方法学定位

它的核心已经包含竞争机制、贝叶斯推断与 VOI，因此三段式流程本身不再是创新点。其验证包含酶动力学、力学与神经元等模型化环境——不能直接证明真实药物筛选中未知的干预强度可被处理，但也意味着“提出假设—模拟—选实验框架”会被直接驳回。

因此本课题的主张句式

不写“首次实现假设—模拟—实验闭环”，而写：“在同一预算与同一证据菜单下，相对 EIG/VOI 与检索型智能体基线，降低错误研发动率，并保持可审计的停止行为。”

查新结论的边界：本次检索未识别出已经完整覆盖上述限定任务、并同时给出独立真实案例决策收益与前瞻正交验证的工作。这是一个有边界的查新结论，不是对全领域“无人做过”的证明——若在启动后发现直接先例，正确反应是调整主张句式，而不是调整评测协议。

公开数据能承担什么，以及不能据此声称什么

核心

右栏比左栏重要。本节是一份数据可行性清单，不是已完成的数据审计：本报告未获得当前版本的所有文件，也未计算可用靶点与条件的实际交集。下一步需固定具体版本、逐文件核查，才能给出案例数量与训练预算。

资源	适合承担的任务	不能据此声称
DepMap + PRISM/GDSC/CTRP ^[61]	候选冲突识别、背景关联、遗传到药理预测	天然同条件配对、真实占有率、逐例机制真值
CPJUMP1 ^[57]	并行化学/遗传形态响应；不同条件的隐藏结果实验	形态相似即同机制；具有降解/救援/暴露的完整面板
Jost 表达滴定 ^[48]	检验强度条件化与阈值响应	直接得到小分子占有率，或跨模式的因果映射
CPA 药物组合数据 ^[7]	验证组合 RNA 预测工具	RNA 变化直接等于存活协同
Tahoe / State 相关数据 ^{[10][12]}	单药条件响应、背景表征及检索先验	与遗传数据自动匹配；具备多步细胞轨迹
BATCHIE / Bashi 等 / NCI-ALMANAC ^{[24][60]}	组合策略的真实结果回放及外部测试	所有未测格点有真值；不同门户相互独立

CPJUMP1 是先导评测的最佳起点^[57]

303 个化合物、160 个基因、A549 与 U2OS 两个细胞系。化合物 24/48h、CRISPR 96/144h、ORF 48/96h——这个时间差是需要保留的模式—时间混杂，而非数据缺陷（第 15 节）。

优先获取的三类内容

处理后的孔级特征、实验元数据与原始来源映射。暂不下载全部图像或一亿单细胞。首轮交集表须含 ModelID/化合物结构/靶点/干预模式/剂量/时间/终点/重复数/来源，以及缺失原因。

首轮交集表的字段规范

字段规范

身份: model_id · cellosaurus_id · tissue
干预: compound_inchikey · gene_symbol · reagent_type(KO/KDi/ORF/degrader)
尺度: nominal_dose · measured_strength (多为 NULL) · exposure_time_h
状态: missing_reason ∈ {未测/测了未公开/质控不合格/实验不可执行} — 禁用 NULL 统一表示
来源: source_portal · source_study_id · dedup_cluster_id

三个字段决定了整份数据能否用于本课题：measured_strength 目前几乎全为空——这个空列本身就是方向一的存在理由；missing_reason 把“没有数据”拆成四种状态；dedup_cluster_id 防止把同一原始实验的多个派生记录当作独立证据。必须固定 DepMap 发布版本、化合物本体版本、细胞系映射表版本三者，任意一个变动都会改变交集结果，须与代码一同纳入版本控制^[22]。

跨案例决策评测的可执行形式

核心

每个案例是一套有限、真实、带成本的证据菜单。开始时只公开源干预与目标干预的基础结果及必要元数据。不存在的实验标为不可用，不能用预测器代填。

强度层一 · 公共面板

以 CPJUMP1^[57] 等构建，用于预测与证据选择的开发。能检验是否更快发现响应条件；不足以证明所有失效机制。

强度层二 · 历史案例包

由公开机制论文构建。有判别证据，但易受发表偏差与 LLM 记忆污染影响。

强度层三 · 冻结后新实验

未发表或新做的实验，用于确认因果预测与实际决策收益。只有这一层能承担最终发现主张。

查询结果与最终检验必须分离：可按预算揭示的实验属于适应数据；另有一组始终不供策略读取的结果，用来检验跨干预预测、所选修正方案与停止决定。若把所有标签逐步揭示完再评价预测，很容易把记忆与拟合当成泛化。

划分与对照

划分与对照	执行方式
开发/验证/最终测试	AKT、BET 等经典例只进开发集。超参数与停止阈值由验证集确定，最终测试一次性使用
关联实体分组	同靶点/同家族、化合物系列绑定在同一侧；分别报告新条件、新化合物、新靶点三种难度
成功与失败案例并存	包含可迁移、不可迁移、条件可修正与证据不足四类案例，防止“永远怀疑/永远停手”取巧
来源污染控制	固定检索语料；隔离能泄漏隐藏结论的正文与补充材料；承认预训练污染难以完全排除
正向与反向对照	删去关键证据、替换无关背景、打乱模型预测、保留反对初始假设的真实结果
成本计量	以孔数、关键试剂/制备负担与周转时间计，不用工具调用次数替代

一个案例的行动菜单长什么样

可揭示的行动	孔数	周转	可用性
近端功能测定 @48h	24	3 天	可揭示（高判别力，直接区分 H1）
靶点占有 / CETSA @6h	24	4 天	可揭示（中，区分暴露 vs 功能）
全转录组 @144h	192	14 天	可揭示（低——时间窗已被代偿掩盖）
降解剂对照 @24h	48	7 天	需试剂（高，直接区分 H2）
耐药等位基因救援	96	21 天	不可用——本案例无构建

这张表说明了为什么成本与判别力必须同时出现：全转录组的孔数是近端功能测定的 8 倍，判别力却更低。只看信息量而不看成本与时间窗的选择器，会系统性偏向大规模组学。对证据不足的案例，正确暂缓计为成功行为；人类基线必须注明经验、时间与可访问资源，不能把一次弱 LLM 输出称为专家流程^[29]。

指标、基线与收益归因

核心

主指标建议只选一个：固定实际预算下的错误研发行动率。每个案例的可接受行动集合与最低证据门槛由独立评审事先确定；不要求每例只有唯一正确的实验序列。

指标	用途与注意事项
错误行动率及置信区间	分别统计错误推进与过早放弃；允许合理暂缓，同时防止全部拒答
达到证据标准的累计成本	只比较达到同一可靠性水平的策略；同时报告周转时间
未见条件预测的适当评分	连续读数用误差与区间覆盖，离散结果用 Brier/log score；不用全基因相关性包办
信念更新与反证响应	新证据反对初始解释时能否改变判断；避免只按解释文字的流畅度评分
前瞻机制验证命中率	仅检验事先登记、且不同假设预测分歧的实验；完整报告失败

最低基线集合

固定专家规则流程；预算匹配的人工评审；简单响应模型 +EIG/VOI；检索型单智能体；同一 LLM 的 MDA 式显式假设决策^[26]；完整系统。若转向组合筛选，另须纳入 BATCHIE 与 ScreenShot^{[24][25]}。

模块互换：把收益定位到具体来源

固定决策器、替换响应模型⇒测试预测信息的增量。固定响应模型、替换决策器⇒测试规划与更新的增量。必要对照：去掉模型、去掉自适应反馈、打乱模型预测。

成绩表模板：六行五列，缺一行结论就不成立

策略	错误行动率	达标累计成本	前瞻命中率	恰当暂缓率
① 固定专家规则流程	•	•	n/a	•
② 简单模型 + EIG/VOI	•	•	•	•
③ 检索型单智能体	•	•	•	•
④ 同 LLM 的 MDA 式决策	•	•	•	•
⑤ 完整系统	•	•	•	•
⑥ 完整系统 · 打乱模型预测	•	•	•	•

第⑥行是最关键的一行，也是最常被省略的一行：如果打乱模型预测后系统表现不变，那么第⑤行相对第③行的全部优势都来自流程与提示词，与世界模型无关——按第 29 节退出条件，模型应移出回路。AUROC/AUPRC、RMSE、Top-k 命中率属于预测层指标，不应出现在同一张表上（第 50 节）。统计单位是案例或靶点簇，绝不是单细胞数量^[31]。

验证是一架梯子，不是一个开关

核心

2026 年的“可信虚拟细胞”路线图^[72]提出了一个本报告完全采纳的原则：主张的野心越大，所需的最低证据等级越高。它同时给出六种典型失效及其防护手段——这份清单比任何模型改进都更值得先执行一遍。

证据阶梯：主张 → 最低证据

你想主张的	最低必需证据
注释 / 插补	内部留出验证
机制发现 / 调控因子提名	正交扰动数据 · CRISPR / Perturb-seq 证伪实验
药物优先级排序	影像 / 形态学确认
转化分诊	类器官 / 组织背景验证

本课题的主张落在第二、三行之间：机制发现+调控因子提名。因此最低证据要求是正交扰动数据加上至少一次前瞻证伪——这正是第 40 节把“是否存在可落实的桥梁实验路径”设为八周关卡的原因。没有这条路径，主张就必须自动降级到第一行。

四个必须联合指定的数据层

- ✓ 分子状态：扰动分辨的分子状态空间
- ✓ 干预：扰动身份、模式、剂量、时间与重复结构
- ✓ 生物学背景：空间、时间、生理与群体变量
- ✓ 正交表型：转录组之外的测量，防止自我确证

六种典型失效与对应防护

失效模式	防护
隐藏支撑泄漏	面向具体场景的分布外划分
转录组自我确证	用蛋白、影像、功能正交验证
指标错配	与任务挂钩的指标（扰动排序、通路还原）
过度自信的不确定性	校准检验与选择性预测策略
事后合理性	干预一致性测试；把机制先验放进架构
插值伪装成外推	支撑诊断：报告到训练样本的距离

可解释性的四个层级



第16节所列系统几乎全停在①②；VCR-Agent 向③推进；④目前无人到达——正是方向三要处理的对象

该路线图对当前能力的总体判断，本报告完全同意：现有虚拟细胞是决策相关（decision-relevant）的，但还不是决策独占（decision-exclusive）的——可用于候选排序、机制聚类与临床前分诊，但每一条建议都仍需实验验证。

AKT、BET 与五个机制控制案例

核心

AKT/BET 的作用是开发与深度证伪。它们有合适的模式差异与既有文献，可用来训练团队如何定义证据、设计桥接实验，但不能再计为最终盲测靶点。最终验证须使用独立化合物、背景或预注册条件。

案例	待区分的解释	关键比较及边界
AKT 抑制 / 降解 ^[49]	更强的表型来自作用持续时间、亚型覆盖、功能去除，还是其他作用	匹配近端功能抑制与时间过程；降解更强不自动证明非催化功能
BET 抑制 / 降解 ^[50]	BRD2/3/4 覆盖范围、bromodomain 功能与其他蛋白功能、动力学不同	先核对具体试剂的作用谱；不可把 BET 家族药物与单一 BRD4 KO 视为同一干预
PRMT5 / MTAP ^[53] ^[54]	背景改变功能耐受，还是代谢条件变化化合物作用	作为已知条件性作用的开发控制；测状态而不只读基因型
PARP trapping ^[51]	抑制剂需要蛋白存在并形成有毒复合物	作为“KO 不复现不等于脱靶”的反例
MELK / OTS167 ^[52]	表型主要不依赖名义靶点	作为纠正机制归因的开发控制，不作为新发现

一次有价值的深度验证应事先登记互斥预测

例如：在经测量确认的相近近端功能抑制轨迹下，急性蛋白去除仍产生额外表型，而适当的功能分离救援可消除这一差异。反之若轨迹匹配后差异消失，结论应改为干预实现或动力学差异——这个改写必须是事先约定的。

耐药等位基因救援本身也需被验证

须验证其功能、表达、定位与选择性的改变。实验阴性结果必须附带检测能力与干预有效性的证据，否则“没看到差异”与“没能力看到差异”无法区分。

一组最小 AKT 桥接面板的具体设计

组	干预	读数与时间点	孔数估计	它能排除什么
A · 剂量梯度	ATP 竞争性抑制剂，6 个浓度	p-AKT 底物 @2h/24h；存活 @72h	6×3×3=54	建立名义剂量→功能残余 r 的映射，全部后续比较的坐标轴
B · 降解对照	AKT 降解剂，剂量按 r 匹配	蛋白丰度+近端功能 @2h/24h；存活 @72h	4×3×3=36	r 对齐后若表型差异消失→排除非催化功能解释
C · 遗传对照 ^[48]	CRISPRi 滴定（强度可调）	同上，外加 @96h 存活	4×3×3=36	区分慢性适应与急性去除
D · 亚型对照	AKT1/2/3 单独与组合敲低	存活 @72h/96h	7×3=21	排除亚型覆盖差异这一替代解释

这份面板的设计逻辑：规模之所以能这么小，是因为 A 组先把坐标轴建立起来——有了 r 的映射，B、C、D 三组都可按 r 匹配而非按浓度匹配来设计，实验组数可减少一个量级。若 A 组做不出可靠的 r 映射，后三组都不应启动——这是本面板的内部停止条件。第一轮只选一组：AKT 或 BET，另一个留作复制与压力测试。

首轮八周的交付物与停止标准

核心

下表是建议的可行性阶段，不是对完整因果课题工期的承诺。默认有一名计算研究者主导，能获得定期的生物学评审；**新增湿实验的速度取决于协作与试剂。**

时间	具体工作	可审阅交付与关卡
第 1-2 周	固定源数据版本；检查化合物、细胞与条件交集；构建少量证据包	交集与缺失表、案例入选规则、隐藏结果清单。若无法形成多个可比较行动，暂停机制决策承诺
第 3-4 周	复现规则与简单模型基线；用处理后特征搭建揭示接口	至少一个可复现的公共任务、不可变划分、成本表与日志。先排除泄漏与伪冲突
第 5-6 周	接入单智能体与一个响应模型；执行预算匹配回放与模块互换	8-12 个先导案例的配对结果，区分模型收益与策略收益，含失败与拒答记录
第 7-8 周	冻结原型；由实验合作者审核一组桥接实验及未见案例来源	预注册预测、实验清单、停止标准。若无真实验证路径，改为较弱主张或替代方向

继续的条件

初始证据确有不能被单一便宜规则解决的竞争解释；至少一些可执行实验对这些解释给出不同结果；完整方法在验证集上显示具有实际意义的成本或错误率改善。


修改的条件

若模型提高表达预测却不改变实验选择→降低角色；若信念机制只复述检索文献→改为结构化基线；若冲突主要来自时间与平台不匹配→先修数据定义。

停止或转向的条件

只有两个已知案例；没有任何未揭示的真实实验；增益仅在同一模拟器内成立；正式预算下无法超过固定流程。此时不靠更大的 LLM 或更多角色补偿证据缺口。

图 40.1 · 八周排程



八周结束时应当拿得出手的五份文件：① 数据交集与缺失表（含固定的三个版本号）；② 冻结的划分与成本表；③ 一张第 37 节格式的成绩表，含打乱对照那一行；④ 8-12 个先导案例的完整轨迹日志；⑤ 一页预注册。五份文件中没有一份是模型权重——这是本报告对“首轮该交付什么”最直接的回答。可借鉴 Biomni 的工具环境^[33]，但专用的状态与行动接口应保持简洁——第 30 节的四层契约就是它的全部。

41 SECTION 41 OF 56

从瓶颈到方向：为什么最终只保留三个

核心

初稿曾列出六个方向。经过第 33 节的查新复核，其中两个被降级为对照，一个被并入其他方向。保留一个方向的标准只有三条：对应一个不会随算力自然消失的瓶颈；没有直接先例；有一个能在低成本下给出明确结论的第一步实验。

方向	名称与技术线索	对应瓶颈	第一步成本
一	干预实现的不确定性建模 · 多尺度：剂量→占有→功能→表型	② 干预实现未被观测 · ① 上下文覆盖	零 · 纯计算
二	交互残差分解与剂量自治监督 · 剂量尺度：同药自组合约束	⑤ 增益不可归因（组合场景的特例）	零 · 纯计算
三	多模态能力边界图谱 · 用模态分歧定位不可信区	③ 无校准、不会拒答	低 · 需已有多模态数据

被降级或并入的三个方向，以及处理方式

降级 · 潜空间预测（Cellular JEPA）

原因：Cell-JEPA 已于 2026 年 2 月公开^[9]，构成直接先例。处理：作为可替换体清单中的模型对照，而非独立方向。

降级 · 好奇心/集成分歧驱动的实验选择

原因：属于 query-by-committee 既有家族，按最不确定选点会优先挑到无行动价值的条件。处理：作为第 37 节基线之一。

并入 · 假说判别式实验设计

原因：MDA 已包含竞争机制+贝叶斯更新+VOI 的完整方法学^[26]，三段式本身不再是创新。处理：并入第三部分作为系统的基础机制，不再单列。

三个方向共享一个主题：它们都不试图把预测做得更准。方向一问“我们究竟做了什么干预”，方向二问“非加性的那部分有多大、估得准不准”，方向三问“这个预测在什么条件下可以被相信”——三者合起来，就是第 3 节能力矩阵里“知道自己不可信”那一行的三种具体实现。这也是它们与领域主流路线的根本分野：主流在优化 E[误差]，本议程在刻画误差的条件分布。

三个方向的一句话主张，以及各自的置信度

方向	可被证伪的主张句	置信度	最先该做的一步
一	在同一预测骨干下，以估计的功能残余为条件，比以名义剂量为条件显著降低跨背景误差，并减少无效补测。	合理推测	E0：滴定数据上的纯计算前提检验（2 周）
二	显式参数化并单独正则化的交互残差，配合同药自组合一致性监督，在 leave-drug-out 下优于隐式交互与 one-hot 基线。	待验证	在公开组合矩阵上直接实现并对照（3 周）
三	模态间分歧能预测模型误差，其信息量高于模型自报置信度与集成方差。	合理推测	在已有配对多模态数据上做相关性检验（2 周）

一条务实的提醒：三个方向并非必须全做（依赖关系见第 49 节）。若只能做一个，应做方向二（唯一可完全独立启动）；若有实验协作，应做方向一；方向三更适合作为前两者的伴随交付物。

方向一：把“干预实现”从一个假设变成一个被建模的潜变量

核心

所有扰动预测模型都隐合同一个假设：标签“化合物 X @ 1 μM”唯一确定了细胞受到的干预。第 31 节的证据说明这个假设在真实数据上系统性地不成立。本方向提案：把功能残余 r 显式建模为一个潜变量，让模型在 r 而非名义剂量的坐标上做预测与比较。

图 42.1 · 核心结构改动



g 随化合物、细胞、暴露条件而变； V 随背景而变——把两者混在一起，正是三类竞争解释无法区分的根源

形式化

$$r = g(d; \text{compound}, m, t, c), \quad g \text{ 关于 } d \text{ 单调递减} \quad y = V(r; c, t) + \varepsilon$$

现有模型学的是复合函数 $V \circ g$

当 g 变化（换化合物、换细胞、换暴露条件）时，模型把 g 的变化误记为 V 的变化——把药理学差异误读成生物学差异。 V 在同一靶点的不同化合物间应共享，而 g 是化合物特异的。

为什么这不是“多加一个输入字段”

r 在绝大多数数据中不可观测，是潜变量不是特征（第 43 节说明如何识别）。它改变的是比较的坐标系：按 r 匹配的实验设计使实验组数减少一个量级（第 39 节）。它给出可执行的分诊规则。

三类不对齐在这个形式化中各自的位置：“名义剂量 ≠ 功能抑制率”是 g 的化合物与暴露依赖；“慢性敲除 ≠ 急性去除”是 g 与 V 的时间依赖；“靶点标签 ≠ 完整作用谱”意味着存在第二条并行的 r' 作用于另一个 V' ——前两类可被模型处理，第三类只能被检测出来，不能被解决。诚实的定位：本方向的增量是三点——把强度建模为潜变量、给出识别约束（第 43 节）、用决策指标而非预测指标评价（第 44 节）。功能测量作为上下文这一现象本身，ScreenShot 已经证明^[25]。^[45]^[47]^[48]

方向一：模型、训练，以及潜变量的可识别性

核心

把 r 设成潜变量会立刻遇到一个反对意见：既然它几乎从不被观测，模型怎么可能学到它？这是一个正确的反对，也是本方向成立与否的关键。本节给出三类可用的**约束**，并明确指出在什么条件下 r 是不可识别的。

约束一 · 单调性与结构

g 关于剂量单调递减，在固定化合物与背景下满足占有率饱和形状。用单调网络直接写进架构。这是可识别性的主要来源。

约束二 · 共享 V

同一靶点的不同化合物共享同一个 V （同背景同时时间窗）。多个化合物的剂量响应曲线必须能被同一条 V 曲线加上各自的 g 解释——经典的平行线检验思想。

约束三 · 自组合一致性

同一药物与自身组合须等价于单药剂量相加（Loewe 的同药自检性质）。这给出无需新数据的监督信号（第 45 节），把 r 的标度钉住——前两条做不到这一点。

可识别性的准确陈述：只有约束一与二时， g 与 V 只能被识别到一个共同的单调重参数化——对任意单调 φ ，把 g 换成 $\varphi \circ g$ 、 V 换成 $V \circ \varphi^{-1}$ ，所有预测完全不变。这不是缺陷，因为跨条件比较只依赖 r 的序，不依赖标度。但若要把 r 解释为“百分之多少的功能被抑制”，就必须用约束三或少量真实测量把 φ 钉住。

● 待验证

这一区分决定了主张的强度：序不变的用法今天就成立，标度解释必须等实验。

与经典药理学的关系

g 的单调饱和形式就是 Hill/占有率模型， V 是剂量—响应曲线——这两样东西药理学用了一百年。本方向不是重新发明它们，而是在成千上万个化合物×细胞背景的规模上共享 V 的结构，使单个化合物只需极少数数据就能定位它的 g 。

训练方案：两阶段，半监督

- ✓ 阶段一：在有强度标注的少量数据上拟 [48]、少数占有率数据、自合 g （CRISPRi 表达滴定序列 建桥接面板 A 组）
- ✓ 阶段二：冻结 g 的形状族，在大规模无标注数据上联合拟合 V
- ✓ 贯穿：施加约束三的自治损失，把标度钉住并抑制 g 与 V 之间的漂移

必须做的四个消融

消融	它排除的解释
去掉 r ，直接端到端	增益是否来自中间变量本身
把 r 换成随机值	增益是否来自额外参数量——最重要的一项，对应第 18 节 one-hot 实验的教训
去掉单调约束	增益是否来自结构先验
去掉自治损失	标度约束是否真的有用

方向一：实验设计、基线与证伪判据

核心

本方向的第一步不需要任何新的湿实验，可以立即执行、并在两到四周内给出明确结论。这一点很重要：它把一个听起来需要大量资源的方向，变成一个先花两周验证前提、再决定是否投入的方向。

阶段	做什么	成本	成功判据 / 失败判据
E0	前提检验（纯计算）。在 CRISPRi 表达滴定数据 ^[48] 上比较按名义强度建模与按实测残余建模	零 · 2周	成功：后者显著降低跨背景误差。失败：无差别⇒中间变量不承载信息，整个方向停止
E1	可识别性检验（纯计算）。在合成数据上验证仅用三类约束能否恢复真实 g 的序	零 · 2周	成功：秩相关高且对噪声稳健。失败：无法恢复⇒需真实强度标注，方向降级
E2	分诊价值检验（纯计算）。用估计出的 r 区间对 DepMap 遗传—药理冲突分诊，与人工标注对比	零 · 3周	成功：准确率高于元数据规则基线。失败：不如规则基线⇒作为特征提供者保留
E3	桥接面板（湿实验）。第 39 节的 AKT 或 BET 四组面板，约 294 孔	中 · 4–6周	成功：按 r 对齐后跨模式表型差异显著缩小。失败：差异不变⇒支持存在额外蛋白功能
E4	决策收益检验。把 r 感知的模型接入第 30 节四层架构，按第 37 节成绩表评测	中 · 4周	成功：错误行动率或成本改善，且打乱对照下降。失败：打乱后无变化⇒移出回路

必须超过的基线

名义剂量版本的同一模型（最重要）；层级剂量响应模型（经典药理学做法）；CPA/LPM 的原始形式^{[7][8]}；ScreenShot 式“把功能测量直接当上下文”^[25]；元数据规则分诊（用于 E2）。

三条会让本方向被判定为失败的结果

① E0 无差别——最便宜也最可能的否定结果，必须第一个做。② 名义剂量基线打平。③ 预测改善但决策不变，按第 29 节退出条件降级。

这个阶梯的设计原则值得推广到另外两个方向：五个阶段的成本递增，而每一阶段的失败判据都能独立终止整条链。最坏情况下的投入是两周，而不是一个学期——把“可能失败”设计进计划，而不是把它留给运气，这是第 40 节停止标准在单个方向内部的具体落实。

45 SECTION 45 OF 56

方向二：把交互残差显式化，并用同药自组合为它提供免费监督

核心

CPA 已经把组合效应表示为潜空间中的可加叠加，并诚实报告了“主导效应”失效：组合数据不足时，模型退化为只预测较强的单药^[7]。问题的根源在于——非加性的那一部分被隐含在解码器的非线性里，因此既无法被单独正则化，也无法被单独评测。

显式分解

$$\begin{aligned} z(A@dA, B@dB) &= z_{\text{basal}} + e_A(dA) + e_B(dB) + \\ &\quad \Delta(e_A, e_B; c) \\ L &= L_{\text{recon}} + \lambda \| \Delta \| + \mu L_{\text{selfconsist}} \end{aligned}$$

同药自组合一致性

$$\begin{aligned} L_{\text{sc}} &= E \| e_A(d1) + e_A(d2) + \\ &\quad \Delta(e_A(d1), e_A(d2); c) - e_A(d1+d2) \| ^2 \end{aligned}$$


这个约束为什么是免费的

它只需要单药的剂量序列——本领域最充足的数据之一（GDSC、CTRP、PRISM、Tahoe 全都有）。组合数据稀缺，单药剂量序列不稀缺。 $\lambda \| \Delta \|^2$ 的作用是让交互项默认为零——模型必须“付出代价”才能主张非加性。

约束的来源：Loewe 的同药自检性质

一个药物与它自己组合不可能产生真实的协同——这是 Loewe 相加性按构造满足、而 Bliss 一般不满足的性质（第 8 节）。它真正约束的是模型学出的有效剂量标度，恰好是方向一中 g 的逆——两个方向在此处相交。

图 45.1 · 监督信号从哪里来



一条含 n 个剂量点的序列可派生约 $n(n-1)/2$ 个约束；一个含千级化合物的剂量矩阵可派生十数量级的监督样本

必须声明的三条适用边界：① 该等式在理想药理学下精确成立，但在溶解度上限、非线性摄取下会失效，只能在经验证的剂量区间内施加。② 本方案用剂量序列作为自组合的代理，这是一个建模假设，应用少量真实同药自组合实验抽检。③ 它只在对角线（同一药物）上直接约束 Δ ；对真正不同的两个药物， Δ 仍需组合数据——它消除的是一大类退化解，不是替代组合数据。

诚实的新颖性定位：同药自检性质是经典药理学常识（Loewe, 1920 年代），潜空间可加分解是 CPA 的做法^[7]，都不是本报告的发现。本方向主张的增量是三者的组合：把交互残差显式参数化并单独正则化、把同药自检转化为可微自监督损失、为交互残差设立独立的评测指标（第 46 节）。第二点是最需要先被验证的一点。 ● 待验证

方向二：训练方案、评测协议与证伪判据

核心

本方向的评测协议必须被第 18 节的 one-hot 发现重写：把药物与细胞系表示换成零信息 one-hot 后，五个已发表协同模型性能持平甚至更好；leave-drug-out 切分下还不如取训练集平均值^[16]。任何不含这两项对照的组合建模结果都不可信。

两阶段训练

阶段一 · 只用单药数据，拟合 $e_A(\cdot)$ 与 Δ 的对角线行为，施加 L_{sc} ，完全不使用任何组合数据——因此组合数据可全部留作评测。阶段二 · 引入有限组合数据，冻结 e ，只更新 Δ 的非对角部分。

一个干净的可测量指标

达到给定组合预测精度所需的组合样本数。若加入 L_{sc} 后该数量显著下降，方案成立；若不变，则自治约束没有提供有效信息——不依赖任何主观判断，且可在公开数据上直接算出。

四种必须分别报告的切分

切分	检验的能力
随机切分	仅作参考，不作为任何结论的依据
leave-drug-out	主结论的唯一依据：对未见药物是否仍有效
leave-cell-line-out	跨背景迁移（对应瓶颈①）
leave-combo-mechanism-out	对未见机制组合类型的外推——最难的一档

交互残差需要它自己的指标：整体预测误差会被可加部分主导，从而掩盖 Δ 的好坏。必须单独报告 Δ 的符号命中率（协同/拮抗方向是否正确）与量级误差，且只在真实非加性确实存在的子集上统计。

六项统一消融清单

#	消融	它排除的替代解释
①	去掉 L_{sc}	自治约束是否真的提供信息，还是仅起正则化作用
②	去掉显式 Δ （退回 CPA 式隐式交互）	显式参数化本身是否带来增益
③	λ 置零（不惩罚交互）	“默认可加”这一先验是否必要
④	把 Δ 换成随机向量	增益是否只来自额外参数量
⑤	one-hot 替换：药物与细胞系表示换成零信息编码	模型是否只学到了实体身份与数据集偏置 ^[16]
⑥	LLM / 骨干替换（若系统含 LLM 组件）	增益是否来自骨干而非所提方法 ^[13]

三条会让本方向被判定为失败的结果：① 加入 L_{sc} 后，达到同等精度所需的组合样本数不下降；② 在 leave-drug-out 下不优于取平均值这一平凡基线；③ one-hot 替换后性能不降。三者中任意一条成立，本方向即应终止，而不是换一个数据集重试——换数据集重试正是让 one-hot 问题在文献中存活多年的原因^{[24][25][60]}。

方向三：用模态分歧绘制模型的能力边界图谱

核心

第 13 节的判断是：多模态在 2026 年已被广泛用于提高预测，这条赛道相当拥挤。本方向提出一个更窄、也更少人做的用法：**把多模态用于判断模型何时不可信**。核心假设——当不同测量通道对同一条件给出不一致的图景时，该条件很可能落在模型的能力边界之外。

能力边界图谱 · 以（背景 × 干预模式）为坐标，以实测误差为值

误差低 · 可用 误差中 · 谨慎 误差高 · 应弃权 无数据 · 不可评估

图 47.1 能力边界图谱示意（非真实数据）。灰格才是重点：模型在这里既没有支撑，也没有自知。交付形式是一张表，而不是一个模型

“模态分歧”具体怎么算：五个可直接实现的特征

特征	定义	它捕捉的失效
效应量符号冲突	转录组位移显著，但形态/存活效应量接近零或方向相反	模型把技术性位移当成生物学响应
跨模态排序秩差	同一组条件在两个模态下按效应量排序的秩相关	模型在该区域学到的是模态特异伪影
重复内 vs 模态间方差比	模态间差异 / 同模态重复间差异	比值接近 1 说明分歧只是噪声，应排除——必需的对照
到训练支撑的距离	该条件在各模态表示空间中到最近训练样本的距离	插值伪装成外推（第 38 节失效之六）
条件元数据异常	时间窗、剂量、模式是否落在训练分布之外	已知混杂未被覆盖

三个可分别检验的子命题

① 分歧预测误差：模态间分歧与模型实际误差正相关，信息量高于自报置信度。② 分歧可迁移：能迁移到未见条件，成为可用弃权规则。③ 弃权带来决策收益：在第 37 节成绩表上降低错误行动率——唯一真正重要的一条。三条递进，第一条可在两周内用已有配对数据^{[57][58]}直接检验。

与两种现有做法的区别

集成方差/query-by-committee 跨的是相关模型，共享同样的盲区；模态分歧跨的是独立测量通道。模型自报置信度由同一组参数产生；模态分歧是外部信号。保形预测给区间，图谱给位置——二者互补。

方向三：对抗式证伪协议与可交付物

核心

绘制图谱需要知道去哪里找失败。均匀采样是低效的：模型的失效区通常很窄。本节提出一个专门的搜索程序——一个目标函数是“让模型自信地出错”的智能体，用最少的查询把边界画清楚。

对抗目标

$$\max_x |\hat{y}(x) - y(x)| \times \text{conf}(x)$$

两项相乘是关键。只最大化误差，会找到模型已经知道自己不确定的区域——那没有危害。只最大化置信度，会找到模型确实擅长的区域。二者的乘积才对应“自信地错”，也就是唯一真正危险的失效。在研发决策中，一次自信的错误推进所造成的损失，远大于许多次小误差之和——平均误差是错的目标函数。

协议：四步，每步都有明确产物

步	动作	产物与判据
P1	在留出集上拟合“模态分歧→误差”的映射	一个可用的误差预测器。判据：预测能力显著优于模型自报置信度
P2	用该预测器引导搜索，在尚未揭示的条件中挑出可能自信且错的候选	一份按危险度排序的候选清单，每条附预测值与置信度
P3	按预算揭示清单前若干项的真实结果	命中率：清单前 k 项中确实“自信且错”的比例，对照随机采样
P4	把确认的失效点聚合为分区图谱，并导出弃权规则	能力边界图谱 + 弃权策略；在第 37 节成绩表上检验决策收益

交付物一 · 能力边界图谱

一张按（背景×干预模式×剂量区间）分区的表，每格标注实测误差、支撑密度与建议行为。它是一份数据产品，不是一个模型——可独立发布、独立更新。

交付物二 · 自信错误案例集

P3 中确认的失效点，构成专门的困难基准。这类基准目前不存在——现有基准都是按数据可得性而非按难度构建的。

交付物三 · 弃权策略

一条可直接接入第 30 节 L2 层 abstain_reason 字段的规则。这是三个方向中唯一能直接改变系统行为的产物。


一条必须预先声明的风险：对抗式搜索可能收敛到数据质量差而非模型能力差的区域。防护办法是在 P3 中对每个确认的失效点强制核查数据质量标记，把“数据问题”与“模型问题”分成两类分别统计。若绝大多数失效点最终归为数据问题，本方向的结论应改写为一份数据质量报告——那依然有价值，但不是原本主张的那个价值。

三个方向的依赖关系与投入顺序

核心

三个方向不是三个并行的选项。它们之间有真实的依赖：方向二的自治约束为方向一提供标度；方向一与二产生的失败案例是方向三的原始材料；方向三产出的弃权规则又会反过来改善前两者在决策评测中的表现。

图 49.1 · 依赖关系



左端的评测基础设施是三个方向共同的前置，因此优先级最高；决策评测结果反馈，决定各方向是否继续

顺序	投入项	周期估计	为什么排在这个位置
1	评测基础设施（第 26、36 节的四项组件）	2-3 周	三个方向共用；不建它，任何方向的结果都无法被判定。一次投入、三处复用
2	方向二：交互残差 + 自治监督	3-4 周	唯一完全不依赖新数据的方向；其产出的标度约束是方向一的输入
3	方向一 E0-E2：前提、可识别性、分诊价值	5-7 周	纯计算，三个失败判据任一触发即可终止，最坏情况投入两周
4	方向三 P1：分歧→误差映射	2 周	可与第 3 项并行；用的是已有配对数据，不占用新资源
5	方向一 E3：桥接实验面板	4-6 周	唯一需要湿实验的一项；只在 E0-E2 全部通过后启动
6	方向三 P2-P4 与决策系统集成	4 周	需要前面产生的失败案例作为材料

方向一 · 最大风险

E0 直接失败——公开数据中的实测强度样本太少。对冲：E0 用 CRISPRi 表达滴定数据^[48]，那里强度轴密集且干净，是最有利的检验场；若在那里都失败，结论是可靠的。

方向二 · 最大风险

自治约束只起正则化作用，与随机正则等效。对冲：把“达到给定精度所需组合样本数”作为主指标，而非精度本身——样本效率的改善不能由普通正则化解释。

方向三 · 最大风险

失效点主要归因于数据质量而非模型能力（第 48 节已声明）。对冲：预先规定两类失效分别统计；即使全部归为数据问题，产出仍是一份有价值的^{数据质量图谱}。

整个排程的一个特征值得指出：前四项、约十二周的工作全部是纯计算，且每一项都有独立的失败判据。这意味着在投入任何湿实验资源之前，团队就能对三个方向各自的可行性得到明确结论。如果四项全部通过，第 5 项的实验投入是有依据的；如果其中若干项失败，那么“失败”本身就是可发表的方法学结论——第 51 节的四个任务正是按这个标准设计的。

八个可独立启动、可分工、可分别验证的候选任务

核心

前五部分给出的是判断与方向。本部分把它们细化为八个可以分别派给不同人、分别验证、分别失败的任务，并标注每项属于哪个能力层、依赖什么前置条件。这是一份选项清单，不是承诺全部执行。

选项	任务	能力层	对应方向	判断与前置依赖
A	跨干预机制诊断与补证决策	L3	方向一	主线 · 需至少一条桥接实验路径；否则收缩为预测与证据获取评测
B	组合验证的序贯证据获取决策	L2-L3	方向二	条件替代 · 需可揭示的真实复测；须超过 BATCHIE/ScreenShot
C	证据质量与可比性分诊	L0-L2	方向一前置	立即可做 · 无湿实验依赖，是 A 的前置模块，也可独立成文
D	模式一时间对齐的响应预测与校准基准	L1	方向一/三	立即可做 · 无湿实验依赖，直接服务 M2 关卡
E	DTI 机制解释的可反驳证据链	L0-L2	方向三	中等门槛 · 工作量集中在留出证据集与污染隔离，不在模型
F	通路和网络先验的决策增益消融	L1	—	立即可做 · 与 D 共用管线，边际成本低
G	组合候选的有效性分诊（非协同分数）	L0-L2	方向二前置	起步任务 · 不含序贯选择，不必正面对抗主动学习基线
H	设计任务的可验证性接口（多肽/配体）	—	—	条件启动 · 需已存在可执行的合成或测活路径

为什么把 C、D、F、G 单列出来

它们都不依赖湿实验、都能在公开数据上得到明确结论、且各自有清楚的失败判据。任何一项做不出来，都会直接影响主线 A 的可行性判断——它们既是独立课题，也是 A 的风险探测器。

两套指标不能混用

AUROC/AUPRC、RMSE、Top-k 命中率适用于 D、F、G 的预测层。A、B、E 必须改用第 37 节的决策指标：错误行动率、达标累计成本、反证响应。混用会让预测层的漂亮数字为决策层的主张背书。

八个选项与三个方向的对应关系：任务是组织单位（谁来做、交付什么），方向是科学单位（要检验什么命题）。C 与 D 为方向一提供数据分诊与分层基准；G 与 B 是方向二的静态与序贯两个版本；E 与方向三共享“留出证据+反证响应”这套基础设施；F 独立于三个方向，但检验的“先验是否带来决策增益”是第 37 节收益归因方法的第一次实地演练。C 与 G 是分诊，D 与 F 是预测与归因，E 是解释的可证伪化，A 与 B 才是完整的决策任务——先做浅层不会浪费，跳过浅层直接做 A 不可能被评审接受。

可立即启动的四项：C、D、F、G

核心

每项都给出最小可行版本、必须超过的基线，以及成功与失败的判据。**失败判据写在前面**，是为了让“做不出来”也成为可交付的结论，而不是延期。

C · 证据质量与可比性分诊

做什么：对同一靶点/化合物的异质记录，判定真冲突/条件不可比/证据不足，并列出其可比所需的最小补充信息。最小可行：固定数据版本，人工标注 30–50 组冲突。最强基线：元数据规则检查^{[61][22]}。成功：把伪冲突从实验清单中剔除；失败：只复述元数据字段。

D · 模式—时间对齐的响应预测与校准基准

做什么：不训练新模型，构建把干预模式与时间点显式作为条件的评测划分，比较线性基线、层级剂量响应模型与 CPA/LPM/State。最小可行：以 CPJUMP1 结构为骨架^[57]，报告分层误差与校准。最强基线：简单线性基线^[15]。

F · 通路和网络先验的决策增益消融

做什么：把通路和基因网络传播作为世界模型的可替换输入，用第 37 节的模块互换测它改善的是拟合还是行动排序。最小可行：无先验/真实先验/打乱边先验三组对比。成功：先验带来可归因的决策增益；失败：只提高相关性不改变选择。

G · 组合候选的有效性分诊

做什么：对已有组合矩阵候选做静态分诊——总杀伤、相对单药增益、协同定义敏感性、重复稳定性、背景选择性，输出推进/复测/放弃三类建议。最小可行：在一个矩阵上定规则并冻结，在另一来源去重后的矩阵外部检验^{[59][60]}。

四项都遵守同一条“最强基线”纪律：基线必须是便宜且笨的那个——C 的基线是元数据规则检查，D 的基线是线性模型，F 的基线是无先验同骨干，G 的基线是固定阈值。这四个基线的共同点是都不需要机器学习——如果一个方法连它们都超不过，那么后续所有复杂度都没有意义。第 18 节的三条负面证据之所以成立，正是因为有人认真地做了这件本该是常规的事。

四项的共同性质：都可以在两到四周内得到可判断的结论，交付物形式一致——一份冻结的规则或划分、一张对照表、一份完整日志。这也正是第 40 节第 1–4 周关卡所需的材料。更重要的是，四项合起来恰好构成第 49 节所说的“评测基础设施”——它们不是热身，它们就是地基。

需要条件的四项：A、B、E、H

核心

这四项各自需要一个前置条件才能启动。把条件写在最前面，是为了避免最常见的一种失败：在条件不具备时启动，然后用系统复杂度掩盖证据缺口。

- A · 跨干预机制诊断与补证决策（主线）

做什么：第 28–32 节已完整定义。启动条件：至少一条可落实的桥接实验路径；若八周内未形成，收缩为跨干预预测与证据获取评测，或转向 B。最强基线：简单响应模型+EIG/VOI；同一 LLM 的 MDA 式决策^[26]。
- B · 组合验证的序贯证据获取决策

做什么：从真实组合存活矩阵出发，决定何时复测、补完整剂量矩阵、或不推进表面协同的候选。启动条件：存在可按预算揭示的真实复测或另一背景结果。最强基线：BATCHE 的贝叶斯主动设计；ScreenShot 的少样本预测^{[24][25]}。
- E · DTI 机制解释的可反驳证据链

做什么：对一个 DTI 或作用方式断言，产出带出处的证据链，并事先写明什么结果会推翻它。启动条件：先建成留出证据集与检索语料隔离（第 36 节）。最强基线：检索型单智能体；VCWorld/VCR-Agent 的结构化解释^{[13][27]}。失败判据：证据引用完整但反响应应为零。
- H · 设计任务的可验证性接口

判断：首轮不启动完整分子生成。没有合成或测活路径时，设计输出停在打分层，无法被证伪。若要保留，最小形式：为设计输出定义可验证性检查表——可合成性、可测活性、对照化合物、明确失败判据。

选项	启动条件（缺则不启动）	条件不具备时的降级方案	八周内能否判定条件
A	至少一条可落实的桥接实验路径	收缩为跨干预预测与证据获取评测，或转向 B	能 · 第 7–8 周由实验合作者审核
B	存在可按预算揭示的真实复测或另一背景结果	只检验候选选择，不宣称检验了质量诊断	能 · 第 1–2 周数据审计即可确认
E	留出证据集与检索语料隔离已建成	降为结构化解释基线的复现工作	能 · 属于可自行建设的内容
H	可执行的合成或测活路径 + 事先写定的成功判据	只做可验证性检查表，作为输出规范	否 · 取决于外部协作

A、B、E 三项共用同一套基础设施：证据表、留出结果、成本表、完整日志。因此即使最终只推进其中一项，前期建设也不浪费。H 不共享这套设施——这正是它被单独标为条件启动的原因。把小组原定的四个核心问题对照一遍：Q1（多源融合）由 D、F 承担；Q2（组合协同与拮抗）由 G、B 承担；Q3（机制层面解释）由 E、A 承担；Q4（转化为可验证候选）由 A、H 承担——四个问题都有落点，但落点的证据强度不同，不应在同一篇论文里同时主张。

三套分工组合与 M1-M4 里程碑

核心

同样的八个选项，按可用资源可以组成三种不同的推进方式。选择依据是**有没有湿实验协作、有几个人、以及能接受多长的验证周期**——不是哪个方向听起来更前沿。

组合一 · 无湿实验，单人，八周

C → D → F。交付一份冻结的证据分诊规则、一份分层校准基准，以及先验消融的对照结果。产出定位：方法与基准类短文，或主线 A 的可行性报告。对应里程碑：M1-M2。

组合二 · 小组四角色分工

文献角色建 E 的留出证据集；数据角色做 C；模型角色做 D 与 F；智能体角色搭 A 的原型与日志。产出定位：一个可演示原型加四份可独立评审的交付物。对应里程碑：M2-M3。

组合三 · 已落实实验协作

A 为主线，C 作前置模块，B 保留为备选，H 在合成或测活路径存在时条件启动。产出定位：带前瞻机制验证的完整工作。对应里程碑：M3-M4。

里程碑

里程碑	该阶段应完成的选项	关卡：过不了就不进入下一阶段
M1 · 认知	C 的冲突分类规则草案；方向地图与术语表	能否写出可判别的冲突分类，而不是一份名词列表
M2 · 基线	D、F、G 各自的冻结划分与对照结果	至少一个可复现的公共任务，划分不可变，泄漏与伪冲突已排除
M3 · 原型	A 的原型接入 C；预算匹配回放与模块互换	能区分收益来自模型还是选择策略；含失败与拒答记录
M4 · 验证	A 的桥梁实验，或 B 在独立矩阵上的外部检验	冻结系统之后取得的独立检验结果，而非同一批数据的再拟合


三套组合共享同一条停止规则：如果在正式预算下无法超过固定流程，不用更大的 LLM、更多角色或更多图谱来补偿证据缺口——选项数量增加的是可选路径，不是可以同时主张的成果数量。最容易犯的错误是按人数而不是按验证能力选组合：四个人并不自动意味着可以选组合二，其前提是四份交付物能被分别评审；若四人共享同一份数据与同一个模型，得到的是一份交付物加三份返工。按第 24 节的几何衰减律，并联的人手只在彼此不串行依赖时才提高产出。

怎么合起来：三个融合层级，与它们各自的证据强度

核心

第 0 部分把两个主角分开讲，这里要回答它们怎么合。本报告的核心结论是：“合起来”不是一件事，而是三件性质完全不同的事。领域里可靠的成果几乎全部落在第一层，却常被用来论证第三层的主张——把三层分开，是读懂这个领域全部宣传话语的钥匙。

图 54.1 · 三个融合层级



层级	需要虚拟细胞提供什么	现状与本报告判断
一 · 工具级	一个稳定的表示与查询接口	证据强 · 表示学习路线已交付可用组件（第 7 节）。今天唯一可以放心落地的层级
二 · 闭环级	分布、校准、适用域、拒答——第 29 节的接口约定	证据部分 · BATCHIE、DeMeo 等已证明闭环可行 ^{[24][28]} ，但虚拟细胞的增量贡献尚未被单独证明
三 · 范式级	可靠的反事实与机制约束	证据薄弱 · 无任何真实预算下的前瞻验证；受第 6 节可执行性缺口限制

层级一做对的标志

研究者在日常工作中真的会去调用它，且调用结果不需要再人工核对一遍。衡量方式是使用频次与返工率，不是准确率。

层级二做对的标志

在第 37 节的成绩表上，打乱模型预测那一行显著变差——这是唯一能证明世界模型确实参与了决策的证据。

层级三做对的标志

系统提出的干预方案，在冻结之后由独立实验验证成功，且该方案是人类专家在同等信息下未提出的。目前无人达到。

三层之间不是连续的，而是有硬门槛的：从一到二的门槛是接口（第 28 节），从二到三的门槛是可执行性（第 6 节）——本报告的方向一同时是跨越两道门槛的必要条件，这不是巧合，而是把问题拆对之后自然出现的结构。一个对小组直接有用的判断：若目标是尽快产出可信成果，应停在层级二；若目标是争取更大的学术影响，应瞄准层级二到三的门槛（即方向一），而不是直接宣称达到了层级三——直接宣称层级三，是这个领域最常见、也最容易被评审击穿的表述。^{[29][72]}

融合成立的四个必要条件，与 Q1–Q5 的回答

核心

上一节说明了融合分三层。本节回答：要让层级二真正成立，还缺什么？四个条件各自对应前文的一处具体缺失，且都是必要条件——缺任何一个，闭环都会退化成更复杂的流水线。

① 世界模型必须会说不知道

没有 in_distribution 与 abstain_reason，决策层无法区分“模型有把握”与“模型在猜”。缺口位置：第 29 节接口；由谁补：方向三。

② 干预必须被建模为可能未实现

把执行 a 当作确定实现了 a，会让跨模式比较的结论无法归因。缺口位置：第 31 节锚点；由谁补：方向一。

③ 成本必须以实验单位计量

用工具调用次数代替孔数与周转时间，会让所有更省的结论失去意义。缺口位置：第 36 节协议；由谁补：评测基础设施。

④ 暂缓必须是被奖励的行为

若弃权与答错同分，系统会被优化成永不弃权，闭环反而放大风险。缺口位置：第 26、37 节；由谁补：评测基础设施。

对五个核心问题的回答

问题	回答	依据与限定
Q1 多源异构数据能否有效融合？	能，但有条件	表示层已可用（第 7 节）；真正配对的资源只有两个（第 11 节）。建议后期融合为主
Q2 能否预测组合的协同与拮抗？	部分能	见过的背景内可以；leave-drug-out 下现有模型不如取平均 ^[16] 。方向二正是针对这一缺口
Q3 能否给出机制层面的解释？	能生成，不能验证	VCR-Agent 已让解释可结构化核验 ^[27] ，但核验对象是文献一致性。因果验证需前瞻登记+冻结检验
Q4 能否转化为可验证的候选？	能排序，不能定论	即“决策相关但非决策独占” ^[72] 。候选排序、机制聚类、临床前分诊今天可用，每条建议仍需实验验证
Q5 本课题应当如何定位自己？	做评测，不做规模	近期最适合投入可审计的实验决策方法与真实证据评测集，而不是新的模型规模

四个条件之间的关系不是并列，而是有顺序的：③④属于评测协议，不需要任何新方法，今天就能满足；①②需要新的建模工作，分别对应方向三与方向一。因此正确的推进顺序是先满足③④，再去做①②——否则即使①②做成了，也无法在一个错误的评测协议下被证明有效。Q5 的回答值得展开一句：这个领域目前不缺模型，缺的是能判断模型有没有用的方法。一个小组若在未来一年内交付一套被他人采用的决策评测协议与数据集，其长期影响力很可能高于再训练一个模型，且失败风险更低——评测集即使得出“所有方法都不行”的结论，也仍是一个有价值且可发表的结果。

如何看待这份报告的确定性，以及一页行动清单

核心

本报告的内容分属四个置信度层级。依据本报告做资源分配决策时，应优先信赖前两层，把后两层当作“值得投入第一步验证实验、但尚未被证明”的假设来对待。

已确立事实

论文的存在与报告的数字。全部 2025–2026 年条目均经独立网络检索核实其存在，包括 MDA、Cell-JEPA、ScreenShot、VCR-Agent、OPAL、in-the-wild 基准与两篇 2026 年综述。核实中修正一处：OPAL 的正确标题此前记录有误。

文献支持的结论

批判性评价与瓶颈归纳：线性基线、one-hot、上下文覆盖三条负面证据；六大瓶颈；几何衰减律与 MAST 分类；六项修正。基于论文自身消融或独立评测，非本报告主观判断。

合理推测

理论框架与整合方案：第三部分的四层架构、接口契约、可靠性预算，第四部分的评测协议，以及 Q1–Q5 的回答。基于已确立事实与文献结论做的合理外推，尚未经过本报告之外的实证检验。

待验证设想

第五部分的三个方向。技术路径具体、有据可查，但目前仅是提案，其有效性完全有待第一个验证实验的结果检验。其中方向二的剂量自治监督为本报告自创，风险最高，也最需要先验证。

一页行动清单

时间	做什么	判断依据
第 1–2 周	建评测基础设施的四项组件（第 26 节）；启动任务 C 的数据审计	能否形成多个可比较的行动
第 2–4 周	方向二：在公开单药剂量序列上实现自治监督，跑消融①④⑤	所需组合样本数是否下降
第 3–5 周	方向一 E0：滴定数据上的前提检验；方向三 P1：分歧→误差映射	E0 无差别即终止方向一
第 5–8 周	任务 D、F、G；方向一 E1–E2	M2 关卡：泄漏与伪冲突已排除
第 8 周	决策点。按第 40 节的三组条件判定继续/修改/停止	是否已落实衔接实验路径

特别提醒：第五部分的三个方向不是三个已经论证过的好主意，而是三个设计好的实验。它们的价值在于每一个都能在低成本下给出明确的正面或负面结论——而不在于它们听起来有多合理。如果八周之后三个方向全部得到否定结论，那么这八周依然是成功的：团队将拥有一套可复用的评测基础设施、三条被排除的路径，以及一份比现在准确得多的领域判断。这正是本报告从头到尾坚持“把失败判据写在前面”的理由。

参考文献（一）：虚拟细胞、评测与智能体系统

核心

编号与正文一致。预印本以 预印本 标示，其结果不视为已独立复现的成熟能力。2025–2026 年发表的条目均经独立网络检索核实其存在与基本信息。

A · 蓝图、表示与扰动预测

1

Bunne C, Roohani Y, Rosen Y, Theodoris CV, Regev A, Leskovec J, Quake SR, 等. How to Build the Virtual Cell with Artificial Intelligence: Priorities and Opportunities. *Cell* 187(25):7045–7063, 2024. arXiv:2409.11654.

2

Theodoris CV, 等. Transfer learning enables predictions in network biology (Geneformer) . *Nature* 618:616–624, 2023.

3

Cui H, Wang C, Maan H, Pang K, Luo F, Duan N, Wang B. scGPT: toward building a foundation model for single-cell multi-omics using generative AI. *Nature Methods* 21:1470–1480, 2024.

4

Rosen Y, Roohani Y, Agarwal A, 等. Universal Cell Embeddings: A Foundation Model for Cell Biology. bioRxiv 2023 → *Nature*, 2026.

5

Hao M, Gong J, Zeng X, 等. Large-scale foundation model on single-cell transcriptomics (scFoundation) . *Nature Methods*, 2024.

6

Roohani Y, Huang K, Leskovec J. Predicting transcriptional outcomes of novel multigene perturbations with GEARS. *Nature Biotechnology* 42:927–935, 2024.

7

Lotfollahi M, Klimovskaia Susmelj A, De Donno C, 等. Predicting cellular responses to complex perturbations in high-throughput screens (CPA) . *Molecular Systems Biology*, 2023. PMC10258562.
含真实药物组合转录组及未见组合预测；原文自报“主导效应”失效边界

8

Miladinović Đ, Höppe T, Chevalley M, 等. In silico biological discovery with large perturbation models (LPM) . *Nature Computational Science* 5:1029–1040, 2025. arXiv:2503.23535.

9

ElSheikh, 等. Cell-JEPA: Latent Representation Learning for Single-Cell Transcriptomics. arXiv:2602.02093, 2026.
预印本 · 零样本聚类 AvgBIO 0.72 (scGPT 0.53)；自报表达状态改善未充分转化为扰动效应量改善

10

Arc Institute. State: predicting cellular perturbation response across diverse contexts. bioRxiv, 2025. doi:10.1101/2025.06.26.661135.
当前发布含非商业许可限制，转化部署需另核许可

11

Arc Institute. Stack: In-Context Learning of Single-Cell Biology. bioRxiv, 2026. doi:10.64898/2026.01.09.698608.

12

Tahoe Therapeutics. Tahoe-100M: A Giga-Scale Single-Cell Perturbation Atlas. bioRxiv, 2025. doi:10.1101/2025.02.20.639398.

13

Wei Z, Ma R, Wang Z, Li Z, Song S, Zheng S. VCWorld: A Biological World Model for Virtual Cell Simulation. arXiv:2512.00306. ICLR 2026.

14

Xing E, Song L. A World Model of the Virtual Cell. GenBio AI, 2026.

B · 评测、基准与批判性证据

15

Ahlmann-Eltze C, Huber W, Anders S. Deep-learning-based gene perturbation effect prediction does not yet outperform simple linear baselines. *Nature Methods* 22:1657–1661, 2025. doi:10.1038/s41592-025-02772-6.
五个基础模型+两个深度模型；修订中补入 Geneformer、scBERT、UCE，结论不变

16

Çandır EB, Kuru Hİ, Rattray M, Çiçek AE, Taştan Ö. One-hot news: drug synergy models shortcut molecular features. *Bioinformatics*, 2026. PMC13005728.

17

Benchmarking Transcriptomics Foundation Models for Perturbation Analysis: one PCA still rules them all. arXiv:2410.13956, 2024.

18

Arc Institute. Virtual Cell Challenge: Toward a Turing test for the virtual cell. *Cell*, 2025. PubMed 40578317.

19

Arc Institute. The 2026 Virtual Cell Challenge: predicting perturbation responses in cell contexts a model has never seen. 2026.
零样本；六个未见细胞系（三验证、三隐藏）；六项指标聚合排名

20

Benchmarking virtual cell models for in-the-wild perturbation response. arXiv:2604.27646, 2026.
预印本

21

Dibaeinia P, Babu S, 等. Virtual Cells Need Context, Not Just Scale. bioRxiv, 2026. PMC12919078.
2200 万细胞 T 细胞数据集；上下文多样性而非细胞数量驱动跨背景泛化

22

Hafner M, 等. Growth rate inhibition metrics correct for confounders in measuring sensitivity to cancer drugs. *Nature Methods* 13:521–527, 2016.

方法学立场：所有“可以做”的陈述均为待验证设想，所有“已经成立”的陈述均标注原始研究出处，两类陈述不得在同一句中混写。

参考文献（二）：智能体系统、机制与可靠性

核心

本页条目构成第 34 节“最近邻工作”与第 37 节“最低基线集合”的来源。其中 25、26、29 为 2026 年预印本，不预设其优势在本任务上可复现。

C · 智能体系统与科研自动化

- 23 Roohani Y, 等. BioDiscoveryAgent: An AI Agent for Designing Genetic Perturbation Experiments. ICLR 2025. arXiv:2405.17631v3.
- 24 Tosh C, Tec M, Tansey W, 等. A Bayesian active learning platform for scalable combination drug screens (BATCHIE) . *Nature Communications* 16:156, 2025. doi:10.1038/s41467-024-55287-7.
探索 140 万种可能实验的约 4% 后准确预测新组合；尤因肉瘤 PARP+拓扑异构酶 I 组合经后续实验确认
- 25 de Mathelin A, Tosh C, Tansey W. ScreenShot: A Foundation Model for Few-Shot Combination Drug Screening. arXiv:2608.12219, 2026.
预印本 · 40 个筛选数据集、3700 药物、6000 样本；基于功能测量做上下文学习，无需分子谱与微调
- 26 Murphy K. Model Discovery Agent: LLM-assisted Bayesian experiment design for data-efficient discovery of mechanistic world models. arXiv:2608.09696, 2026.
预印本 · LLM 提结构+SMC 后验+SBI+VOI；验证域为物理、化学与单神经元电生理
- 27 Jang, 等. Towards Autonomous Mechanistic Reasoning in Virtual Cells (VCR-Agent) . arXiv:2604.11661v2, 2026.
预印本 · 机制作用图形式化 (20 个生物学原语)、验证器过滤、18,950 条 VC-TRACES
- 28 DeMeo B, 等. Active learning framework leveraging transcriptomics identifies modulators of disease phenotypes. *Science* 390:ead8577, 2025.
- 29 Certifying when decision-time information justifies adaptive experimentation (OPAL) . arXiv:2607.27651, 2026.
预印本 · 未见的 11,265 化合物分区上，冻结门控选出 595 化合物、384 正机会，误激活上界 $5.18\% < 7.5\%$
- 30 Tang X, Yu Z, Chen J, Gerstein M, 等. CellForge: Agentic Design of Virtual Cell Models. arXiv:2508.02276, 2025.
- 31 Xia X, Yao C, Tsoi M, 等. AblateCell: A Reproduce-then-Ablate Agent for Virtual Cell Repositories. arXiv:2604.19606, 2026.
- 32 Zhang HG, Eckmann P, Miao J, Mahon AB, Zou J. The Virtual Biotech: A Multi-Agent AI Framework for Therapeutic Discovery and Development. bioRxiv, 2026. PMC12970349.
- 33 Huang K, Zhang S, Wang H, Qu Y, Roohani Y, 等. Biomni: A General-Purpose Biomedical AI Agent. bioRxiv, 2025.
doi:10.1101/2025.05.30.656746.
- 34 Li M, Li B, Wang J, 等. CellScientist: Dual-Space Hierarchical Orchestration for Closed-Loop Refinement of Virtual Cell Models. arXiv:2605.07335, 2026.
- 35 Boiko DA, MacKnight R, 等. Autonomous chemical research with large language models (Coscientist) . *Nature* 624:570–578, 2023.
并见 *ChemCrow* · *Nat Mach Intell* 2024; *CRISPR-GPT* · *Nat Biomed Eng* 2025

D · 智能体机制与可靠性

- 36 Wei J, Wang X, Schuurmans D, 等. Chain-of-Thought Prompting Elicits Reasoning in Large Language Models. arXiv:2201.11903. NeurIPS 2022.
- 37 Wang X, Wei J, 等. Self-Consistency Improves Chain of Thought Reasoning in Language Models. arXiv:2203.11171, 2022.
- 38 Yao S, Zhao J, Yu D, 等. ReAct: Synergizing Reasoning and Acting in Language Models. arXiv:2210.03629. ICLR 2023.
- 39 Yao S, 等. Tree of Thoughts: Deliberate Problem Solving with Large Language Models. NeurIPS 2023.
- 40 Shinn N, Cassano F, 等. Reflexion: Language Agents with Verbal Reinforcement Learning. arXiv:2303.11366. NeurIPS 2023.
- 41 Cemri M, Pan MZ, Yang S, 等. Why Do Multi-Agent LLM Systems Fail? (MAST) arXiv:2503.13657. NeurIPS 2025.
- 42 The Illusion of Diminishing Returns: Measuring Long Horizon Execution in LLMs. arXiv:2509.09677, 2025.
单步准确率的微小提升带来可完成任务长度的指数级增长；同时报告自条件化导致的单步准确率衰减
- 43 Diagnosing and Mitigating Context Rot in Long-horizon Search. arXiv:2606.29718, 2026.
- 44 Evaluation and Benchmarking of LLM Agents: A Survey. arXiv:2507.21504. KDD 2025.

本次检索截止于成稿时。查新结论有边界，不构成对全领域“无人做过”的证明。

参考文献（三）：药理与遗传证据、数据资源

核心

E 组是第 31、39 节生物学锚点与机制控制案例的原始研究出处——本报告全部关于“干预实现 ≠ 名义干预”的论证都建立在这十二项原始研究之上；F 组是第 35 节数据可行性清单所涉的公开资源。

E · 药理与遗传证据

45

Gonçalves E, 等. Drug mechanism-of-action discovery through the integration of pharmacological and CRISPR screens. *Molecular Systems Biology*, 2020. doi:10.15252/msb.20199405. 199,219 条药敏测量、397 个药物、484 细胞系；约 50% 的药物可确定作用机制

46

Vermeulen L, Craig M, Babak T. Challenges and opportunities for oncology drug repurposing informed by synthetic lethality. *npj Systems Biology and Applications*, 2025.

47

Krill-Burger JM, 等. Partial gene suppression improves identification of cancer vulnerabilities when CRISPR-Cas9 knockout is pan-lethal. *Genome Biology* 24:192, 2023.

48

Jost M, 等. Titrating gene expression using libraries of systematically attenuated CRISPR guide RNAs. *Nature Biotechnology* 38:355–364, 2020.

49

You I, 等. Discovery of an AKT Degradar with Prolonged Inhibition of Downstream Signaling (INY-03-041) . *ACS Chemical Biology*, 2020.

50

Zengerle M, Chan KH, Ciulli A. Selective Small Molecule Induced Degradation of the BET Bromodomain Protein BRD4. *ACS Chemical Biology*, 2015.

51

Murai J, 等. Trapping of PARP1 and PARP2 by Clinical PARP Inhibitors. *Cancer Research*, 2012.

52

Lin A, 等. CRISPR/Cas9 mutagenesis invalidates a putative cancer dependency targeted in on-going clinical trials (MELK/OTS167) . *eLife* 6:e24179, 2017.

53

Engstrom LD, 等. MRTX1719 Is an MTA-Cooperative PRMT5 Inhibitor. *Cancer Discovery* 13:2412–2431, 2023.

54

Barekatin Y, 等. Homozygous MTAP deletion in primary human glioblastoma is not associated with elevation of methylthioadenosine. *Nature Communications* 12:4228, 2021.

55

Martinez Molina D, 等. Monitoring drug target engagement in cells and tissues using the cellular thermal shift assay (CETSA) . *Science* 341:84–87, 2013.

56

MS CETSA deep functional proteomics uncovers DNA repair programs leading to gemcitabine resistance. *Nature Communications*, 2025.

F · 数据资源

57

Chandrasekaran SN, 等. Three million images and morphological profiles of cells treated with matched chemical and genetic perturbations (CPJUMP1) . *Nature Methods* 21:1114–1121, 2024. 303 化合物、160 基因、A549/U2OS；化合物 24/48h、CRISPR 96/144h、ORF 48/96h

58

Haghighi M, 等. High-dimensional gene expression and morphology profiles of cells across 28,000 genetic and chemical perturbations. *Nature Methods* 19:1550–1557, 2022.

59

Zagidullin B, 等. DrugComb: an integrative cancer drug combination data portal. *Nucleic Acids Research* 47:W43–W51, 2019. 整合数据不能被视为互相独立的外部验证集

60

Bashi A, 等. Large-scale Pan-cancer Cell Line Screening Identifies Actionable and Effective Drug Combinations. *Cancer Discovery* 14:846–865, 2024. 109 组合、755 癌细胞系

61

Broad Institute. DepMap data portal. 动态数据资源；门户访问有验证限制，本报告未下载并核算当前版本的数据交集

62

JUMP Cell Painting Consortium / Carpenter-Singh Lab. CPJUMP1 与 2022_Haghighi_NatureMethods 复现仓库. 处理流程与实验条件入口；本次未执行复现

核实验方法说明 · 核实验范围：本版对全部 2025–2026 年条目执行了独立网络检索，确认其标题、作者、发表载体与核心数字。2024 年及更早的条目沿用前两版记录，未重新检索。已更正一处：条目 29 (OPAL) 此前记为其他标题，检索确认 arXiv:2607.27651 的实际标题为《Certifying when decision-time information justifies adaptive experimentation》，现已更正。未执行的事项：本报告未运行任何模型性能实验，未下载 DepMap、JUMP 或 Tahoe 的完整数据，未计算可用靶点与条件的实际交集，也未复现 CPJUMP1 处理流程。所有涉及数据量的陈述均引自原始论文或官方说明。关于预训练污染：本报告引用的多篇 2026 年工作可能已进入常用模型的预训练语料。第 36 节的评测设计承认这一污染难以被完全排除，并要求在结论中显式注明，而非声称已经控制。

参考文献（四）：跨领域理论、多模态与多尺度

核心

G 组提供本报告在世界模型、离线强化学习与自监督表示方面的理论参照；H 组是本版新增的多模态与多尺度线索，其中 71、72 两篇 2026 年综述为第 14、38 节的框架来源。

G · 跨领域理论

- 63 Levine S, Kumar A, Tucker G, Fu J. Offline Reinforcement Learning: Tutorial, Review, and Perspectives. arXiv:2005.01643, 2020.
- 64 Ha D, Schmidhuber J. World Models. arXiv:1803.10122, 2018.
- 65 Hafner D, Pasukonis J, Ba J, Lillicrap T. Mastering Diverse Control Tasks through World Models (DreamerV3). *Nature* 640:647–653, 2025.
- 66 Assran M, 等. V-JEPA 2: Self-Supervised Video Models Enable Understanding, Prediction and Planning. arXiv:2506.09985, 2025.
- 67 Pathak D, Agrawal P, Efros AA, Darrell T. Curiosity-driven Exploration by Self-supervised Prediction. ICML 2017.
- 68 Lewis P, Perez E, 等. Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks. NeurIPS 2020.
- 69 Pearl J. 因果阶梯（关联/干预/反事实）。见 *Causality* 及 *The Book of Why*.
- 70 Loewe S. 剂量相加性与同药自组合（sham combination）判据。经典药理学文献；见 *DrugComb* 对各协同零模型的整理

H · 多模态与多尺度 · 本版新增

- 71 Artificial intelligence-enabled multi-scale virtual cell: perspective, challenges, and opportunities. *Briefings in Bioinformatics* 27(2):bbag104, 2026.
基因/蛋白/通路/细胞四尺度与三处耦合；三类困难：跨尺度非线性跃迁、模态语义失配、维度爆炸
- 72 Toward trustworthy virtual cells: a roadmap for perturbation-resolved, context-aware, and experimentally validated cell models. *Frontiers in Cell and Developmental Biology*, 2026.
五条可信标准、四个数据层、验证阶梯与六种失效模式；提出“决策相关但非决策独占”的定位
- 73 PAST: A multimodal single-cell foundation model for histopathology and spatial transcriptomics in cancer. 2026.
2000 万对组织病理影像与单细胞转录组，泛癌种
- 74 scpFormer: A Foundation Model for Unified Representation and Integration of Single-Cell Proteomics. arXiv:2604.20003, 2026.
预印本 · 3.9 亿细胞、530+ 蛋白，跨质谱流式、CITE-seq 与多重成像
- 75 SpatialFusion: A lightweight multimodal foundation model for pathway-informed spatial niche mapping. bioRxiv, 2026.
- 76 AI-driven virtual cell models in preclinical research: technical pathways, validation mechanisms, and clinical translation potential. *npj Digital Medicine*, 2025.
- 77 Kraus O, 等. Masked Autoencoders for Microscopy are Scalable Learners of Cellular Biology. CVPR 2024.
- 78 Radford A, Kim JW, 等. Learning Transferable Visual Models From Natural Language Supervision (CLIP). 2021.
对比式跨模态对齐的方法来源
- 79 本报告的两份合订来源：《虚拟细胞×智能体·研究报告》（68 页）与《虚拟细胞与智能体·研究判断》（23 页），以及其中引用的小组研究材料（药物发现智能体小组 PPT，2026）。
两份文件均全文读取；描述任务意向，不证明已有实验资源

本版相对两份来源文件的增补 · 新增九项来源（71–79）：其中 71、72 两篇 2026 年综述分别为第 14 节多尺度框架与第 38 节验证阶梯的直接来源；73–75 构成第 13 节的多模态盘点；77、78 补齐跨模态对齐的方法学出处。新增五节内容：第 11–15 节（多模态三节、多尺度两节）在两份来源文件中均无对应章节，系本版为响应“整合多模态与多尺度信息”的要求而新写。研究方向由六个收敛为三个：潜空间预测（因条目 9 构成直接先例）与集成分歧选择（因属 query-by-committee 既有家族）降级为对照；假说判别式实验设计（因条目 26 已完整覆盖）并入第 28 节作为系统的基础机制（第 41 节）。两个方向在技术上被打通：第 45 节的同药自组合一致性约束，同时是第 43 节中潜变量标度可识别性的来源——这一联系在两份来源文件中均未出现，是本版合订过程中形成的判断，待验证。